

經國
營立
管臺
理北
系科
碩技
士大
班學

碩

士

論

文

連便利
鎖商店
便利使用
商行動
商支
店付
之
▷消費
超者
商行
商為
為研究
例以

研
究
生
：
王
小
明



國立臺北科技大學

資訊工程系碩士班
碩士學位論文

完整的中、英文系所名稱請參考圖書館提供之「[學位論文系所名稱參照表](#)」

基於深度骨架時序模型之幼兒步態發展遲
緩風險輔助評估

Deep Skeleton-Based Spatiotemporal Modeling for
Developmental Delay-Risk Assessment from Toddler
Gait Videos

研究生：古雲鄉

指導教授：白敦文 博士

中華民國一百一十五年七月

此頁為印製紙本論文用 (2025.02.26ver)

上傳電子論文請移除此頁，印製紙本論文時請移除此紅字

此頁為印製紙本論文用 (2025.02.26ver)

上傳電子論文請移除此頁，印製紙本論文時請移除此紅字

(預留空白頁)



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

基於深度骨架時序模型之幼兒步態發展遲
緩風險輔助評估

Deep Skeleton-Based Spatiotemporal Modeling for
Developmental Delay-Risk Assessment from Toddler
Gait Videos

研究生：古雲鄉

指導教授：白敦文 博士

中華民國一百一十五年七月

國立臺北科技大學 (影本)
研究所博士學位論文口試委員會審定書
(碩士)

本校_____研究所_____君

所提論文，經本委員會審定通過，合於博士資格，特此證明。
(碩士)

學位考試委員會

委員兼召集人：_____

委 員：_____

指導教授：_____

所 長：_____

注意事項：

中 華 民 國 一 一 四 年 ○ 月 ○ 日

審定書填寫方式依系所規定，但檢附在電子論文內的掃描檔須具備：

1. 含指導教授、口試委員及系所主管的完整簽名。
2. 口試委員人數正確，碩士口試委員至少3人、博士口試委員至少5人。
3. 若此頁有論文題目，題目應和書背、封面、書名頁、電子論文系統的題目相符。
4. 此頁有無浮水印皆可。

摘要

關鍵詞：幼兒步態分析、發展遲緩、姿態估測、骨架序列、殘差圖卷積網路、標籤分布學習。

本研究提出一套基於電腦視覺之幼兒步態發展月齡輔助評估框架，利用自然行走影片估計幼兒之步態發展月齡。本研究蒐集 12 至 36 個月幼兒以智慧型手機拍攝之正面或背面自然行走影片，影片來源涵蓋居家與臨床等非實驗室環境，並建立一套分析流程，包含姿態估測、多目標追蹤、目標幼兒辨識、骨架正規化、步態片段擷取，以及基於骨架之時序建模。

為聚焦於步態相關之肢體動作特徵，本研究將原始 COCO-17 骨架簡化為八個關鍵關節點，包括雙肩、雙髖、雙膝與雙踝。模型方面，採用殘差圖卷積網路以學習幼兒步態中的空間與時間變化特徵。由於發展月齡具有連續性，並非嚴格的離散類別，本研究進一步採用標籤分布學習預測月齡分布，並以其期望值作為估計之步態發展月齡。

實驗結果顯示，本方法於片段層級達到平均絕對誤差 2.78 個月，Spearman 相關係數為 0.771；於個案層級之平均絕對誤差為 2.79 個月，Pearson 相關係數為 0.803。此外，在 24 個月以上幼兒族群中，基於方向性預測誤差之 z-score 亦展現出辨識發展遲緩風險之潛力。整體而言，本研究結果顯示，基於自然影片之骨架式步態分析具有作為早期發展篩檢輔助工具之可行性。

ABSTRACT

Keywords: toddler gait analysis, developmental delay, pose estimation, skeleton sequence, Residual GCN, Label Distribution Learning.


This study proposes a vision-based auxiliary assessment framework for estimating gait developmental age in toddlers using natural walking videos. Smartphone-recorded frontal or rear-view videos of children aged 12 to 36 months were collected in natural settings. The proposed pipeline integrates pose estimation, multi-object tracking, target-child identification, skeleton normalization, gait segment extraction, and skeleton-based temporal modeling.

To focus on gait-related motion, the original COCO-17 skeleton was simplified to eight key joints, including the shoulders, hips, knees, and ankles. A Residual Graph Convolutional Network was used to model spatial-temporal gait patterns. Since developmental age is continuous rather than strictly categorical, Label Distribution Learning was adopted to predict an age distribution, and the expected value was used as the estimated gait developmental age.

Experimental results showed that the proposed method achieved a segment-level mean absolute error of 2.78 months and a Spearman correlation of 0.771. At the case level, the mean absolute error was 2.79 months, with a Pearson correlation of 0.803. In children aged 24 months and above, directional prediction-error z-scores also demonstrated potential for identifying developmental-delay risk. These findings suggest that skeleton-based gait analysis from natural videos may provide a feasible auxiliary tool for early developmental screening.


誌謝

所有對於研究提供協助之人或機構，作者都可在誌謝中表達感謝之意。



目錄

摘要.....	i
ABSTRACT.....	ii
誌謝.....	iii
表目錄.....	v
圖目錄.....	vi
第一章 緒論(大標).....	1
1.1 研究背景與動機(小標).....	1
1.1.1 研究背景(小小標).....	3
第二章 文獻探討(大標).....	2
2.1 名詞定義(小標).....	錯誤! 尚未定義書籤。
2.2 模型說明(小標).....	3
參考文獻.....	17



表目錄

表 1.1 表格範例標題.....	錯誤! 尚未定義書籤。
表 1.2 範例範例.....	錯誤! 尚未定義書籤。



圖目錄

圖 1.1 圖範例.....	錯誤！尚未定義書籤。
圖 1.2 第二個範例.....	錯誤！尚未定義書籤。
圖 2.1 範例說明.....	錯誤！尚未定義書籤。
圖 2.2 新增.....	錯誤！尚未定義書籤。



第一章 緒論

1.1 研究背景與動機

嬰幼兒發展遲緩為小兒神經學、兒童復健與早期療育領域中重要的臨床議題之一。相關研究指出，2016 年全球 5 歲以下兒童中，約有 5,290 萬人存在發展相關障礙，盛行率約為 8.4%，其中約 95% 分佈於中低收入國家[1]。在台灣，2000 至 2015 年間，0 到 6 歲兒童發展遲緩盛行率由 2.0% 上升至 5.7%；然而，0 到 2 歲嬰幼兒之盛行率相對偏低，可能反映早期發展問題於嬰幼兒階段較不易被辨識，亦可能與醫療照護資源可近性不足、家長警覺性差異及後續轉介流程等因素有關[2]。由於嬰幼兒時期的大腦具有高度神經可塑性，若能及早發現發展異常並提供適當介入，已被證實有助於改善遲緩兒童之長期發展結果[3,4]。因此，如何在發展問題尚未明顯惡化前，建立有效且可普及之早期篩檢機制，已成為臨床與公共衛生領域的重要課題。

在嬰幼兒發展遲緩表現中，可能侷限於單一發展面向，如粗大動作、精細動作、語言、認知或社會互動能力，亦可能同時涉及多個發展領域。當嬰幼兒於一項或多項發展能力上出現顯著落後時，即可能被判定為發展遲緩。其中，粗大動作能力之成熟常被視為整體神經發展的重要指標，而動作發展遲緩亦往往較認知或語言問題更早被觀察到[5]。因此，對粗大動作行為進行系統性觀察，有助於及早發現潛在之神經發展異常。在眾多粗大動作行為中，步態（gait）為反映動作控制、姿勢穩定及神經肌肉協調能力的重要表現，因此成為早期發展評估與相關研究中的重要觀察指標。相較於部分需透過特定測試情境方能誘發之動作表現，步行屬於嬰幼兒日常生活中可自然出現之功能性活動，其表現亦可透過步態之時空參數、左右對稱性、姿勢穩定度及關節運動模式等特徵進行量化分析。隨著電腦視覺與姿態估計技術之發展，步態影像已具備以非侵入方式進行擷取與分析之可行性，使其有潛力發展為一項客觀、可重複且具擴展性的早期篩檢指標。

目前嬰幼兒粗大動作發展之臨床評估，仍多仰賴標準化量表與專業人員觀察。此類工具雖具臨床參考價值，然在人力需求、施測時間與場域限制等因素下，較不利於大規

模社區篩檢與高頻追蹤。因此，若能發展一套以影像或步態訊號為基礎、兼具客觀性與半自動化潛力之評估方法，將有助於提升早期篩檢之可近性與實務可行性，並可作為傳統臨床量表之外之輔助評估工具。

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \quad (1.1)$$

1.2 研究目的

本研究與馬偕紀念醫院早期療育評估中心醫療團隊合作，開發一套以幼兒行走步態特徵分析為基礎之發展輔助評估系統，作為傳統臨床評估之外之輔助篩檢手段，以提升早期發展異常辨識之可近性與效率。本研究以家長於居家環境及偏鄉區公所拍攝之幼兒自然行走步態影片為基礎，建置本國嬰幼兒姿態辨識與粗大動作發展資料集（IRB No: 20MMHIS447e, 23MMHIS113e），並結合人體姿態辨識與多目標追蹤技術，自動擷取步態過程中的身體關鍵點與時序動作資訊，量化幼兒行走步態特徵，以評估其動作發展表現。具體而言，本研究將建構整合幼兒正面與背面自然行走影片之端對端分析流程，涵蓋影像輸入、個體追蹤、姿態篩選擷取、步態特徵建模與風險評估，以建立由原始影片至發展風險推論之自動化系統；並發展以步態表現為基礎之月齡預測方法，探討預測月齡與實際月齡差異作為發展遲緩風險篩檢指標之可行性，同時分析圖卷積網路應用於幼兒步態骨架時序資料之潛力及其於月齡預測與早期篩檢任務中的表現。期望藉此發展出一項客觀、可重複且具擴展性之技術途徑，以降低早期發展篩檢對專業人力與臨床場域之依賴，並為幼兒發展遲緩之早期辨識提供實證基礎。

第二章 文獻探討

2.1 嬰幼兒發展遲緩評估方法

嬰幼兒發展遲緩之早期發現具有重要臨床意義，而粗大動作表現，尤其是站立、步行與步態穩定性，常被視為反映神經動作發展成熟度的重要觀察面向。現行嬰幼兒發展評估方法大致可分為三類：其一為以標準化量表為核心之傳統臨床評估；其二為藉由感測裝置進行量化之動作分析；其三則為近年快速發展之無接觸式電腦視覺分析方法。上述方法在臨床解釋性、量化能力、場域限制與自然行為觀測能力上，各具不同之優勢與限制，值得進一步比較

2.1.1 傳統臨床量表評估

在現行醫療與早期療育體系中，常見之標準化發展評估工具包括畢保德動作發展量表第二版（PDMS-2）[8]、阿爾伯塔嬰兒動作量表（AIMS）[7] 與貝萊嬰幼兒發展量表（Bayley-4）[9]。其中，PDMS-2 適用於出生至 5 歲兒童，評估粗大與精細動作能力，且其 locomotion 子測驗包含爬行、行走、跑跳等項目；AIMS 則主要用於出生至約 18 個月、獨立行走前後之嬰兒粗大動作發展觀察，著重於俯臥、仰臥、坐姿與站姿等姿勢控制及動作里程碑表現，較適合作為早期粗大動作成熟度之篩檢工具；Bayley-4 則為嬰幼兒整體發展評估中具代表性的標準化工具之一，涵蓋認知、語言與動作等多個面向。此類量表具備標準化常模、良好信效度與臨床解釋性，因此至今仍為專業實務中不可或缺之評估依據。

然而，傳統量表之施測通常高度依賴專業人員之觀察、操作與判讀，且多需於受控制之醫療或評估場域中進行，施測時間亦相對較長。對嬰幼兒而言，陌生場域與互動壓力可能影響其自然行為表現，使評估結果未必完全反映其於日常生活中的真實的「生態效度（Ecological Validity）」行為。因此，傳統量表雖具有臨床標準化與專業性優勢，但在自然情境觀測、長期追蹤與高頻率篩檢方面，仍存在一定限制。

2.1.2 基於感測器之步態與動作分析

為補足傳統量表在量化能力上的限制，部分研究採用慣性測量單元（Inertial Measurement Unit, IMU）等穿戴式感測器，以蒐集步頻、步幅、支撐期比例及關節運動等客觀訊號 [10]。此類方法在成人步態分析、復健監測與運動評估領域已展現良好應用潛力，近年亦逐漸延伸至嬰幼兒或兒童動作發展之量化分析[10]。

然而，若將穿戴式感測器直接應用於嬰幼兒場景，仍面臨若干限制。首先，自然場域中的資料蒐集可能受到感測器配戴方式、照顧者介入、訊號漂移與資料遺失等因素影響，增加資料解讀與模型建立之難度[10]。其次，嬰幼兒步態與日常動作本身具有高度變異性與不規則性，也提高了跨個體分析與模型泛化的挑戰[10]。雖然已有研究嘗試結合機器學習方法，以提升穿戴式資料於動作辨識與步態量化任務中的分析效能[11]，亦有研究顯示穿戴式感測器可用於居家情境下追蹤嬰兒動作成熟度，或區辨典型發展與發展風險族群[12,13]，但整體而言，穿戴式感測器之應用仍高度依賴受試者配戴與資料蒐集條件之穩定性。因此，對於強調低干擾、自然場域觀測與大規模普及應用之嬰幼兒篩檢情境，此類方法仍存在一定之實務限制[10]。

2.1.3 基於電腦視覺之無接觸式步態分析

近年來，電腦視覺與深度學習技術之進展，為嬰幼兒動作分析提供了非接觸式之觀測途徑。此類方法可直接透過一般 2D 攝影機、智慧型手機或家用錄影設備，擷取幼兒於自然環境中的動作影像，避免穿戴式設備對行為表現造成干擾，因此在低侵入性、場域彈性與可近性方面具有明顯優勢。過去亦已有研究指出，由家長於居家環境中拍攝嬰幼兒粗大動作影片，並供專業人員進行評估，在實務上具有可行性，顯示影像式方法具有應用於家庭與日常情境觀測之潛力[14]。

在自動化動作分析方面，電腦視覺方法可用於嬰幼兒動作量化與神經動作風險評估。Chambers 等人利用電腦視覺方法自嬰兒影片中擷取姿態與動作特徵，並比較高風險嬰兒與常模資料之差異，指出自動化影像分析具有輔助早期神經動作風險評估之潛力

[15]。Groos 等人針對嬰兒自發性動作進行姿態估測研究，顯示無標記姿態估測已具備應用於嬰兒動作影片分析之可行性[16]。近期國內研究亦將此類方法應用於嬰兒粗大動作發展評估，Yang 等人以居家錄製之嬰兒動作影片為基礎，結合姿態估測、骨架特徵擷取與機器學習模型，自動辨識嬰兒粗大動作發展狀態，進一步支持影像式分析作為早期發展輔助評估工具之可能性[17]

除了應用可行性外，短時間影片是否足以提供穩定的動作量化資訊，也是影像式方法能否用於實務篩檢的重要問題。例如，Pigueiras-del-Real 等人指出，短時間影像已可產生低變異之穩定動作指標，其全身動作變異係數約為 5.46% – 6.40%，且基於關鍵點距離之方法較光流法具更高穩定性[18]。此外，即使僅分析部分身體區域，其結果亦與全身分析相近，差異僅約 1% 左右，顯示局部動作已能有效反映整體發展狀態[18]。

近年亦已有研究將基於影像之無標記步態應用於幼兒步態分析，並驗證姿態估測方法於幼兒步態量化任務中的可行性[19]。此顯示影像式方法不僅能保留幼兒外觀動作表現，亦可能反映其潛在之神經動作發展狀態，因而使無接觸式影像分析逐漸成為嬰幼兒動作與步態研究中具潛力之發展方向。

2.1.4 步態作為年齡與動作成熟度線索之研究脈絡

步態不僅可作為個體識別之行為生物特徵，亦可反映與年齡相關之動作成熟度變化，因此逐漸被應用於年齡估計與發展分析相關任務中[20]。步態是一種具有週期性之運動模式，其表現受到神經系統、肌肉骨骼發育與行走經驗共同影響，並會隨個體成長而逐步成熟[21]。




圖 2.1 幼兒早期步態發展階段與年齡區間示意圖

在發展早期階段，幼兒步態通常呈現較高之不穩定性與變異性，例如步態節律不穩、步幅不一致、寬步距、全腳掌著地及關節協調性不足等現象。隨著年齡增長與神經肌肉系統逐漸成熟，步態之對稱性、協調性與穩定性亦逐漸提升。相關研究指出，幼兒步態在 1 至 3 歲間經歷顯著演進：12 至 15 個月時多以全腳掌著地、寬步距與高步頻維持平衡；約 2 歲後逐漸出現較成熟之腳跟著地與足底壓力轉移；至 3 歲時，其時空參數、對稱性及能量效率逐漸趨於穩定，並朝成人步態模式發展[22]。因此，步態參數與關節運動特徵可視為反映幼兒動作控制成熟度的重要線索。

進一步而言，近期研究已證實多項步態參數，如膝關節間距、軀幹擺動及步行比例等，與年齡具有中度至高度相關性，並可用於建立步態發展年齡之預測模型，顯示僅透過步態資訊即可有效反映幼兒之發展程度[23]。此結果指出，步態不僅為基本移動能力，更可作為量化評估幼兒發展狀態之客觀指標。

在幼兒粗大動作發展自動化評估方面，已有研究嘗試以行走步態特徵建立發展分類模型。例如，蔡嘉銓之研究蒐集 12 至 36 個月幼兒步態影片，透過骨架動作序列與多

項步態特徵，並使用 XGBoost 分類器進行粗大動作發展分類，結果顯示準確率達 71% 以上，證實步態特徵可作為幼兒發展篩檢之可行依據 [24]。黃品宥之研究則進一步針對 18 至 36 個月幼兒之側面步態影片，結合姿態估測、骨架追蹤與機器學習模型，擷取擺盪期比例與關節角度對稱性等特徵，並在不同側向行走方向下皆取得穩定辨識表現 [25]。

綜合上述，步態之時空參數、運動學特徵與神經控制模式皆會隨年齡呈現系統性變化，並與動作成熟度密切相關。因此，若能於自然情境下穩定擷取幼兒之步態特徵，將有助於建立具臨床意義之發展輔助評估方法，作為早期篩檢與風險辨識之重要依據。

2.2 視訊式姿態估測與多人追蹤技術

隨著深度學習與電腦視覺技術之快速發展，基於影像之人體姿態估測 (Human Pose Estimation) 已成為動作分析與步態研究中的核心技術之一。相較於傳統依賴穿戴式感測器之方法，視訊式姿態估測具備非接觸、低干擾與可於自然場域蒐集資料等優勢，因此特別適合應用於嬰幼兒行為觀察與長時間動作監測情境。

人體姿態估測之目標為自影像或影片中定位人體各關鍵點 (keypoints)，並建立骨架結構表示。現有方法大致可分為自頂向下 (top-down) 與自底向上 (bottom-up) 兩類架構。自頂向下方法首先透過目標偵測模型 (如 Faster R-CNN 或 YOLO) 定位人體區域，再於各個人體區域內進行單人姿態估測，此類方法通常具有較高之關鍵點定位精度，但在多人場景中需重複推論，計算成本較高。相對地，自底向上方法則直接於整張影像中預測所有人體關鍵點，再透過關聯演算法將關鍵點組合為個別人體骨架。以 OpenPose 為例，其提出 Part Affinity Fields 以描述身體部位間之連接關係，提升多人姿態估測之效率與可擴展性 [26]。

近年姿態估測研究進一步朝向高精度、即時性與輕量化方向發展。例如，HRNet [27] 透過維持高解析度特徵表示提升關鍵點定位能力，OpenPifPaf [28] 則針對多人場景下之關鍵點關聯進行設計，而 RTMPose [29] 進一步在姿態估測精度與推論速度之間取得良

好平衡。本研究所採用之 RTMO (Real-Time Multi-Object Pose Estimation) [30] 屬於即時多人姿態估測架構，可直接於單一影像中輸出多個人體之關鍵點位置。因此，RTMO 適合用於本研究之自然場域影片，尤其是在嬰幼兒與照顧者可能同時出現之情境下，作為後續步態骨架序列建構之基礎。

然而，單幀姿態估測僅能取得每一影格中的人體骨架位置，並無法保證同一個體於連續影格中的身份一致性。因此，若要建立可用於步態分析之時序骨架序列，仍需結合多目標追蹤 (Multi-Object Tracking, MOT) 技術，以維持跨幀之個體身份一致性。現代多目標追蹤多採 tracking-by-detection 架構，透過目標偵測結果，結合運動預測、外觀特徵或偵測置信度進行跨幀關聯。

早期代表性方法如 SORT (Simple Online and Realtime Tracking) [31]，主要利用卡爾曼濾波 (Kalman Filter) 預測目標位置，並透過匈牙利演算法 (Hungarian Algorithm) 完成跨幀資料關聯。SORT 具備高效率與即時性，但在遮擋、目標交會或外觀相似之情境下，容易產生身份切換 (ID switching) 問題。為改善此限制，DeepSORT [32] 進一步引入深度外觀特徵描述子，透過 Re-identification (ReID) 特徵提升遮擋後之目標再辨識能力。ByteTrack [33] 則提出將低置信度偵測結果納入關聯流程之策略，有效提升追蹤召回率與整體穩定性。

近年提出之 BoT-SORT [34] 進一步整合運動模型、外觀特徵與相機運動補償 (camera motion compensation)，在多種公開資料集上展現良好的追蹤表現。相較於僅依賴位置預測或高置信度偵測結果之方法，BoT-SORT 能在遮擋、多人互動與背景干擾等非理想條件下維持較穩定之身份追蹤結果。因此，本研究採用 RTMO 進行人體關鍵點擷取，並結合 BoT-SORT 進行跨幀身份追蹤，以建立連續且具身份一致性之嬰幼兒步態骨架序列。



圖 2.2 逐幀偵測與多目標追蹤在影片序列中之目標關聯示意圖

2.3 基於骨架表示之步態特徵建模

人體骨架在電腦視覺中通常指以關節點集合描述人體姿態之中介表示。對單一行人而言，單一影格之姿態可表示為多個關節點之空間座標與置信度；將連續影格中的關節特徵沿時間維度堆疊，即可形成步態序列。於資料集層級，則可進一步整合多條步態序列及其對應之身分、視角與環境條件等標註，用以支援跨視角、跨協變因素之評估，以及模型泛化能力分析[35,36]。~~(圖建議：以時間軸呈現「單幀關節 → 步態序列 → 資料集」三層抽象，並於序列層標示左右踝關節之週期性變化。)~~

在步態分析任務中，骨架表示之主要優勢在於能將人體動作結構與影像外觀因素部分解耦。相較於依賴輪廓或原始影像之外觀方法，骨架表示較不易直接受到服裝、光照與背景變化影響，並能保留關節位置、肢段連結與動作時序等結構資訊。因此，關節點所形成之人體結構可進一步轉換為圖表示，使模型得以學習與身份、年齡或動作狀態相關之高階特徵[37]。近年大規模野外步態資料集亦逐漸納入人體姿態資訊作為重要模態之一，顯示骨架表示在非受控場景中具有應用潛力[38]。

然而，骨架方法亦存在對姿態估測品質敏感之限制。若關節點受到遮擋、追蹤錯誤或估測雜訊影響，後續步態特徵學習亦可能受到干擾。因此，早期骨架式方法在實際場景中的表現常受限於姿態估測穩定性與模型對雜訊的容忍能力[38]。隨著骨架時序建模方法的發展，近年研究已逐漸將骨架由輔助模態推向可獨立使用之主要表徵。相關方法

透過時空特徵學習、結構化關節建模與多尺度動作表示，使純骨架模型在受控與非受控場景中皆展現出具競爭力之表現，說明骨架本身已具備獨立承載步態資訊的潛力[39,40]。

在表示形式上，骨架可自然建構為圖結構，其中關節為節點、骨骼連結為邊；若再將相同關節於連續影格間相連，則可形成時空圖。此種表示方式使模型能同時描述關節間之空間協同關係與跨時間之動作變化，適合用於分析步態所具有的週期性、左右對稱性與肢體協調特徵。相關研究指出，透過建模對稱關節互動、階層式動作特徵與週期性先驗，可有效捕捉步態之結構與節律特性[41,42]。因此，相較於將步態僅視為一般時間序列訊號，將其視為多關節協同運動所形成之週期系統，並結合人體結構與時間動態先驗，更能貼近步態分析任務之本質。




圖 2.3 人體骨架序列之跨影格關節位移示意圖

2.4 圖卷積神經網路於人體動作與步態分析之應用

人體骨架序列本質上可表示為由關節點及其連結關係所構成之圖結構，因此在進行動作分析與步態建模時，傳統以規則網格為假設之卷積神經網路（Convolutional Neural Network, CNN）並非最直接適用於此類資料。CNN 主要針對影像等具有固定鄰近關係之資料設計，而骨架資料屬於非歐幾里得結構，其關節間拓撲並不具備規則排列。另一

方面，雖然循環神經網路（Recurrent Neural Network, RNN）或時間卷積網路（Temporal Convolutional Network, TCN）可用於處理骨架時間序列，但若將整體骨架展平成向量進行建模，容易忽略關節之間的空間結構關係，使骨架資料被視為單純的時間訊號[43]。因此，如何同時建模骨架之空間拓撲與時間動態，成為骨架動作分析中的關鍵問題。

為解決上述問題，圖卷積神經網路（Graph Convolutional Network, GCN）逐漸被應用於骨架動作辨識領域。Kipf 與 Welling 所提出之 GCN 架構，定義了在圖結構上進行鄰域訊息聚合的基本形式[44]；Defferrard 等人則從頻域觀點建立圖卷積之理論基礎，使卷積運算能夠延伸至非規則拓撲資料[45]。在此基礎上，Yan 等人提出 Spatial-Temporal Graph Convolutional Network (ST-GCN)，將人體骨架序列建模為時空圖（spatio-temporal graph），其中節點對應人體關節，邊則包含空間上的骨骼連接與時間上的跨幀連接，並結合空間圖卷積與時間卷積進行特徵學習[46]。ST-GCN 在 NTU-RGB+D 與 Kinetics 等資料集上提升了骨架動作辨識效能，奠定後續骨架 GCN 方法發展之基礎。

在 ST-GCN 之後，後續研究進一步嘗試提升圖結構本身的彈性。Shi 等人提出 Two-Stream Adaptive Graph Convolutional Network (2s-AGCN)，引入可學習之自適應鄰接矩陣（adaptive adjacency matrix），使模型能根據資料特性調整關節間連結權重[47]。Chen 等人則提出 Channel-wise Topology Refinement GCN (CTR-GCN)，透過通道層級之拓撲精煉機制，使不同特徵通道能學習不同的關節關係 [48]。此類方法顯示，從固定骨架拓撲進一步擴展至可學習之圖結構，有助於捕捉更複雜的關節交互模式。

然而，自適應圖結構雖能提升模型對不同樣本與動作型態之適應能力，亦會增加模型之學習自由度與結構複雜度。例如 2s-AGCN 透過可學習之圖拓撲，使模型能依據資料動態調整關節連結關係[47]；但相關研究亦指出，近年骨架 GCN 模型逐漸趨於複雜與過參數化，模型訓練與推論效率因而成為需考量之問題[49,50]。在資料規模有限的情境下，過高的模型複雜度可能增加泛化不穩定與過擬合風險，這在小樣本機器學習研究中亦被指出為常見問題[51]。

此外，步態發展相關研究顯示，幼兒步態成熟度與下肢支撐、步幅/步寬、軀幹穩定

及肢體協調等因素密切相關。例如 Tsuyuki 等人指出，knee-to-knee distance、waist height、walk ratio 與 trunk sway 等步態參數皆與幼兒年齡具有中度以上相關，其中 knee-to-knee distance 對步態發展年齡估計之貢獻最大[23]。兒童步態發展研究亦指出，軀幹動作控制及其與四肢協調之關係，是步行動作技能成熟的重要指標[52]。因此，在骨架步態建模中，與下肢支撐、步態節律及軀幹穩定相關之關節，通常具有較高的任務相關性。

然而，在自然場景幼兒影片中，並非所有人體關鍵點皆能穩定提供與步態成熟度直接相關的資訊。頭面部節點容易受到視角、遮擋與姿態估測誤差影響；遠端上肢雖可能參與幼兒平衡調節，但其動作常受到揮手、扶持、拿取物品或與環境互動等非步態因素干擾。因此，若直接使用完整骨架，模型可能同時學習到與步態發展無關的動作變異。基於此，近年部分步態分析與異常步態辨識研究亦採取關節精簡或部位導向設計，以降低冗餘資訊並強化模型對關鍵步態特徵之聚焦能力[53]。

承接上述觀點，既有骨架步態研究亦從圖結構設計與注意力機制等角度，驗證了部位選擇與關節重要性建模對步態辨識之影響。例如，Tian 等人提出之 gait-structural graph convolutional network (AGS-GCN) 在圖結構中加入 gait-specific 連結關係，並透過時空注意力機制強化與步態相關之關鍵關節[43]。Aderinola 等人提出之 PairGCN 則透過區域分群與結構設計，強調不同身體區域，特別是下肢部位，於步態特徵表達中的重要性[37]。上述研究顯示，針對步態任務適當保留或強化與行走相關之骨架結構，有助於提升模型對步態特徵的辨識能力。

綜合上述發展脈絡，骨架圖卷積模型已由早期之固定拓撲建模，逐步發展至自適應圖結構學習，並進一步延伸至部位層級與注意力導向之設計。考量本研究資料規模有限、拍攝場景自然且幼兒步態序列容易受姿態估測誤差影響，本研究採用以人體自然骨架拓撲為基礎之殘差圖卷積網路 (Residual Graph Convolutional Network, Residual GCN) [49] 作為骨架時序建模架構。此架構透過圖卷積保留關節間之空間連結關係，並結合時間卷積以建模跨幀動態變化；同時，殘差連接可提升模型訓練穩定性，降低多層特徵轉換過程中的資訊衰減問題。相較於高度自適應或注意力導向之骨架 GCN 方法，Residual

GCN 具有較簡潔的模型結構與較低的過擬合風險，適合作為本研究幼兒步態發展月齡估計之主要時序建模骨幹。




圖 2.4 基於人體骨架序列之時空圖卷積步態特徵萃取示意圖

2.5 年齡估計與 Label Distribution Learning

年齡估計是一類介於分類與回歸之間的預測問題。若將年齡視為連續數值，模型可透過迴歸方式直接輸出預測年齡；若將年齡劃分為數個類別，則可轉換為分類任務。然而，年齡標籤具有連續性與相鄰相似性，相近年齡之間通常具有較高表徵相似度，而距離較遠之年齡則差異較大。因此，單純以單一硬標籤進行分類，容易忽略相鄰年齡之間的模糊關係；直接以單一數值進行迴歸，則較難描述年齡表現中的不確定性與個體差異。

在電腦視覺年齡估計研究中，Rothe 等人提出 Deep EXpectation (DEX) 方法，將年齡估計轉換為多類別分類問題，並於推論階段以 softmax 機率分佈之期望值作為最終年齡預測結果[54]。此方法說明，年齡估計可透過分類形式學習年齡分佈，再轉換為連續年齡輸出。

基於年齡標籤的連續性，標籤分佈學習 (Label Distribution Learning, LDL) 提供了一種更適合年齡估計的標籤建模方式。不同於傳統單標籤學習僅假設每個樣本對應單一正確標籤，LDL 以一組標籤分佈表示樣本與各標籤之間的關聯程度[55]。在年齡估計任務中，LDL 可將真實年齡附近的標籤設定為較高權重，而距離較遠的標籤給予較低權

重，使模型學習目標由單一硬標籤轉為平滑且具連續性的年齡分佈。

Geng、Yin 與 Zhou 將 LDL 應用於人臉年齡估計，指出老化是一個緩慢且連續的過程，因此以標籤分佈描述年齡比單一標籤更符合年齡變化的本質[56]。Gao 等人進一步提出深度標籤分佈學習（Deep Label Distribution Learning, DLDL），將 LDL 與深度神經網路結合，並透過 Kullback - Leibler divergence 使模型預測分佈逼近目標年齡分佈[57]。

在本研究中，LDL 被用於幼兒步態發展月齡之建模，並透過深度骨架時序網路進行實作，因此本研究方法亦可視為 DLDL 架構之一種應用。模型並非直接預測幼兒的實際生理月齡，而是根據步態骨架序列所反映出的動作成熟程度，輸出其相對應的「預測步態發展月齡」。由於嬰幼兒步態成熟度會隨年齡、行走經驗與神經肌肉骨骼系統發展而逐步改變[22]，相鄰月齡幼兒的步態表現可能高度重疊，同一月齡幼兒亦可能因發展速度不同而呈現不同成熟程度。因此，本研究將實際月齡轉換為平滑的月齡標籤分佈，使模型學習幼兒步態表現與不同月齡階段之關聯程度，而非將相鄰月齡視為完全獨立的類別。




圖 2.5 基於標籤分佈學習之步態發展月齡估計流程

2.6 發展年齡與發展遲緩風險概念

在兒童發展評估中，單一動作表現本身通常不足以直接判定其發展意義，而需結合兒童之實際年齡或實際月齡進行判讀。相同的動作能力在不同月齡階段可能具有不同意涵；例如某一行走或姿勢控制表現在較低月齡幼兒中可能仍屬正常發展範圍，但若出現在較高月齡幼兒中，則可能反映動作成熟度不足。因此，兒童發展評估的重點不僅在於觀察兒童是否具備特定能力，也在於判斷其能力表現是否符合該年齡階段之發展期待。

發展年齡可視為兒童在特定發展領域中所呈現之功能成熟程度。當兒童之發展年齡接近其實際年齡時，通常表示該領域大致符合年齡期待；反之，若發展年齡明顯低於實際年齡，則可能表示該領域存在相對落後現象[58]。然而，發展遲緩之判讀通常不僅依賴發展年齡與實際年齡之差距，也需參考同年齡族群之常模分佈。標準化發展量表通常

會根據常模樣本，將兒童原始表現轉換為標準分數、百分位或標準差單位，以判斷其表現相對於同齡兒童之位置[8,9]。在臨床與研究脈絡中，若兒童於特定發展領域之表現明顯低於同齡常模，例如低於平均數約兩個標準差，通常可視為具有較高發展遲緩風險或需進一步臨床評估之訊號[59]。

上述概念對以步態影像進行幼兒動作成熟度分析具有重要啟發。由於步態成熟度會隨實際月齡、行走經驗、神經肌肉控制與姿勢穩定能力逐漸發展，因此若僅觀察兒童是否能完成特定行走動作，仍不足以判斷其發展意義；更重要的是將其步態表現置於相近月齡兒童的發展脈絡中進行解釋。換言之，若模型所估計之步態成熟程度明顯低於該兒童實際月齡所期待之範圍，則可能反映其步態發展相對落後，並可作為後續發展遲緩風險分析的依據。



第三章 實驗架構與研究方法

3.1 整體系統架構

本研究旨在建立一套以一般智慧型手機步態影片為基礎之嬰幼兒步態發展評估流程，藉由視訊式姿態估測、多人追蹤、骨架前處理與圖卷積神經網路模型，預測受試幼兒之步態對應發展月齡，並進一步分析其發展遲緩風險。整體系統流程可分為資料輸入、影片前處理、骨架擷取與追蹤、骨架正規化、步態片段切割、骨架表示轉換、模型訓練與推論，以及結果分析等階段。

在實際流程上，輸入由正面或背面角度拍攝之嬰幼兒自然步態影片，並統一影片格式與幀率。接著利用姿態估測模型擷取每一影格之人體關鍵點資訊，再結合多目標追蹤方法建立連續之人體骨架軌跡。由於自然場景中可能同時出現家長、照顧者或醫療人員，本研究進一步依人體比例特徵自多條候選軌跡中辨識目標幼兒。完成目標幼兒軌跡確認後，系統再對其骨架序列進行平移與尺度正規化，並依直立姿態、骨架投影比例合理性與步態交替特徵偵測有效步態區段，最後切割為固定長度之骨架序列，作為後續模型輸入。




圖 3.1 基於影片骨架分析之幼兒步態發展月齡估計流程

於骨架表示方面，本研究先以 COCO 17 點骨架進行前處理與目標人物辨識，再將其簡化為 8 個與步態較相關之關鍵點，作為 ResGCN 模型之輸入。最後，模型輸出月齡分佈與其期望值，作為步態發展月齡之預測結果，並進一步透過預測誤差之分佈分析、z-score 標準化及 ROC 曲線評估其於發展遲緩風險辨識之潛在應用價值。

3.2 研究對象與資料來源

本研究之資料由馬偕紀念醫院早期療育評估中心醫療團隊協助提供，研究對象為年齡介於 12 至 36 個月之嬰幼兒自然步態影片。資料蒐集場域包含早療門診及不同篩檢場域，皆屬於貼近實務之非受控情境。拍攝時以智慧型手機搭配腳架進行連續錄影，攝影機放置於距離幼兒約 2.5 公尺處，從幼兒正面或背面角度記錄其自然行走過程，以保留較接近真實步態表現之影像資料。

本研究原始蒐集之幼兒自然步態影片資料，經姿態估測、多目標追蹤、骨架品質篩選與有效步態片段擷取後，最終共有 178 位個案取得符合本研究分析條件之有效步態片段，並納入後續模型訓練與結果分析。表 3.1 顯示最終有效分析個案於不同真實月齡區間之分佈情形。研究樣本包含正常發展組 159 人與發展遲緩組 19 人。正常組主要作為模型訓練、交叉驗證與步態月齡建模之依據；遲緩組則保留作為外部風險分析與遲緩個案觀察使用。

所有研究資料皆已通過馬偕紀念醫院倫理審查委員會審核，核准編號為 IRB No. 20MMHIS447e 與 23MMHIS113e，並於資料蒐集前取得受試者家長或法定監護人之書面同意。為保護個人隱私，所有影片與後續輸出之骨架資料皆採去識別化方式處理，僅供研究分析使用。

表 3.1 有效分析個案依發展狀態與真實月齡區間之分佈

類別	12-18 個月	18-24 個月	24-30 個月	總計
正常	52	52	55	159
遲緩	0	0	19	19
總計	52	52	74	178

3.3 影片前處理、姿態估測與多目標追蹤

本研究之骨架擷取前處理流程包含影片規格統一、姿態估測、人物邊界框過濾、多目標追蹤、骨架品質篩選以及短暫缺失補償等步驟。透過上述流程，可自自然場景影片中建立具有時間一致性且品質穩定之人體骨架軌跡，作為後續步態分析與模型建構基礎。

由於原始影片來自不同拍攝裝置，格式包含 MP4 與 MOV 等類型，為降低裝置差異對後續分析之影響，本研究將所有影片統一轉換為每秒 30 幀，並調整為 1080 × 1920 之直式解析度，以維持姿態估測與骨架序列處理流程之一致性。

在姿態估測部分，本研究採用 RTMO-L 擷取人體關鍵點。該模型可於每一影格中輸出人體邊界框、17 個人體關鍵點座標及其信心分數。為避免影像邊界截斷造成不完整骨架，本研究於姿態估測後加入人物邊界框過濾機制。當偵測到的人物邊界框過於接近影像邊界時，該骨架可能包含身體截斷或關鍵點缺失問題，因此予以排除。本研究將影像四周 1% 範圍視為邊界緩衝區，僅保留完整位於緩衝區內側之人物框，以降低不完整骨架對後續多目標追蹤與步態分析之影響。

在多人物場景中，僅依賴單幀姿態估測結果難以維持分析對象之一致性。因此，本研究進一步採用 BoT-SORT 作為多目標追蹤方法，將跨影格之人體偵測結果關聯為連續軌跡，使同一人物於時間序列中維持一致之身分標記，以降低人物交錯、短暫遮擋或鏡頭晃動造成之骨架序列混淆問題。

完成姿態估測與多目標追蹤後，考量嬰幼兒行走影片中可能出現遮擋、局部出框或姿態估測失敗等情形，本研究進一步進行骨架品質篩選。以每一影格所有關鍵點之平均信心分數作為品質指標；當平均信心分數低於門檻值 τ 時，便將該骨架自影格中移除。本研究設定 $\tau = 0.7$ ，以保留較可靠之骨架影格，並兼顧序列長度之完整性。

此外，為維持骨架序列之時間連續性，本研究對短暫缺失之骨架資料進行時間內插。若相鄰有效骨架影格之間的缺失長度不超過 L_{max} ，則對中間缺失影格進行補值；本研究設定 $L_{max} = 5$ ，以允許短暫遮擋或偵測失敗之補償，同時避免過長時間缺失導致動作語意失真。

經由上述步驟，本研究可自自然場景影片中建立具有時間一致性且品質穩定之人體骨架軌跡，作為後續辨識目標幼兒軌跡、骨架正規化與步態區段偵測之基礎。




圖 3.2 步態影片之幼兒骨架軌跡擷取流程

3.4 目標幼兒軌跡辨識

在前述步驟中，本研究已透過姿態估測與多目標追蹤建立多條具時間一致性之人體骨架軌跡。然而，由於資料來自居家、衛生所及早療門診等自然場景，畫面中常同時包含家長、陪同者或醫療人員，因此仍需進一步自多條候選軌跡中辨識出目標幼兒，以確保後續分析對象之一致性。

因此，本研究進一步以人體比例特徵輔助目標幼兒辨識。相較於外觀、服裝或影像

紋理等特徵，身體比例較不易受到場景變化與短期外觀差異影響，並能反映幼兒與成人在身體結構上的年齡差異。由於幼兒通常呈現相對較長之上半身與相對較短之下肢，本研究參考兒童生長評估中上、下身段比例之概念，透過二維骨架關鍵點與人物邊界框估計影像中的身體比例。此處所得比例主要作為目標軌跡篩選之判定特徵，屬於影像座標下的近似估計，並不同於臨床量尺測量所得之實際人體測量值。

對於第 t 幀，設左右肩、左右髖、左右膝與左右踝之座標分別為 $p_{LS,t}, p_{RS,t}, p_{LH,t}, p_{RH,t}, p_{LK,t}, p_{RK,t}, p_{LA,t}, p_{RA,t}$ ，則肩部中心、髖部中心、膝部中心與踝部中心分別定義為：

$$s_t = \frac{p_{LS,t} + p_{RS,t}}{2}, \quad h_t = \frac{p_{LH,t} + p_{RH,t}}{2}, \quad k_t = \frac{p_{LK,t} + p_{RK,t}}{2}, \quad a_t = \frac{p_{LA,t} + p_{RA,t}}{2} \quad (3.1)$$

其中， s_t 表示肩部中心， h_t 表示髖部中心， k_t 表示膝部中心， a_t 表示踝部中心。頭頂位置則以前景人物邊界框上緣為主要依據，並結合鼻點位置輔助估計，記為 $y_{top,t}$ 。本研究首先定義上身段估計高度與下身段估計高度如下：

$$H_{upper,t} = |y_{s,t} - y_{top,t}| + |y_{h,t} - y_{s,t}| \quad (3.2)$$

$$H_{lower,t} = |y_{k,t} - y_{h,t}| + |y_{a,t} - y_{k,t}| \quad (3.3)$$

$H_{upper,t}$ 表示由頭頂至肩部再至髖部之上身段估計高度， $H_{lower,t}$ 表示由髖部至膝部再至踝部之下身段估計高度。並根據此定義影像估計之上、下身段比例為：

$$R_{USLS,t} = \frac{H_{upper,t}}{H_{lower,t}} \quad (3.4)$$

此比例用以描述上半身相對於下半身之長度關係。幼兒通常上半身相對較長、下肢相對較短，因此可作為區分幼兒與成人之依據。為降低單一影格姿態估測誤差之影響，本研究針對每一條追蹤軌跡，於其站立區段內計算 $R_{USLS,t}$ 之中位數，作為該軌跡之代表性比例特徵。

根據幼兒體態特徵與資料分佈觀察，本研究將上、下身段比例中位數大於 1.3 之軌跡視為候選幼兒軌跡。當同一時間範圍內出現多條候選軌跡時，則以比例中位數最高者作為目標幼兒軌跡，並排除其他重疊軌跡。辨識完成後，系統僅保留目標幼兒之連續骨

架序列，供後續骨架正規化與有效步態區段擷取使用。




圖 3.3 基於人體骨架與身體比例之目標幼兒選取示意圖

3.5 骨架正規化

在完成目標幼兒軌跡辨識後，本研究針對該幼兒之骨架序列進行正規化處理，以降低拍攝位置、人物距離、身體平移及個體尺度差異等非步態因素對骨架時序資料之影響。透過平移與尺度正規化，不同個體與拍攝條件下之骨架資料可映射至一致之相對座標系統，使後續分析更能聚焦於步態動態特徵本身。

在骨架正規化方面，本研究對每一影格之骨架座標進行平移與尺度正規化。首先，以髖部中心 h_t 作為該影格之座標原點，將所有關鍵點轉換為相對於髖部中心之座標；接著，以肩部中心 s_t 至髖部中心 h_t 之距離作為軀幹長度，對骨架尺度進行標準化。對於第 t 幀中第 j 個關鍵點 $p_{j,t}$ ，其正規化後座標可表示為：

$$\tilde{p}_{j,t} = \frac{p_{j,t} - h_t}{|s_t - h_t|_2} \quad (3.5)$$

其中， $|s_t - \hat{h}_t|_2$ 為該影格之軀幹長度。透過此正規化方式，不同拍攝距離、人物位置與個體身形所造成之尺度與平移差異可被降低，使後續模型較能聚焦於步態之時序動態變化，而非影像座標與比例差異。




圖 3.4 幼兒步態骨架座標正規化示意圖

3.6 有效步態區段擷取策略與最終片段建構

完成目標幼兒軌跡辨識與骨架正規化後，本研究進一步自連續骨架序列中擷取具代表性之有效步態區段。在自然場景中，幼兒行走影片常包含起步、停止、轉身或短暫遮

擋等非穩定動作片段；若直接使用完整骨架序列進行建模，可能降低模型對穩定步態特徵之學習效果。因此，本研究依人體姿態與步態動態特徵設計多項條件，自連續骨架資料中擷取具代表性之步態區段。

整體流程為：針對每一影格判斷是否符合特定條件，形成逐幀標記序列，並將連續符合條件之影格合併為候選區段。為提升對短暫骨架不穩定或遮擋情形之容忍度，於部分條件中允許有限長度之中斷，最後再依區段長度與步態特性進行篩選。

本研究之步態區段判定主要包含直立姿態條件、骨架投影比例合理性與步態交替條件三類。

3.6.1 直立姿態條件

為排除坐下、蹲下、爬行或膝關節過度彎曲之影格，本研究以左右膝關節角作為直立姿態之判定依據。膝關節角係由髌、膝與踝三點形成之內角計算而得；當兩側膝關節角皆大於預設門檻時，表示下肢未呈現明顯屈曲，故視為符合直立姿態條件。

既有幼兒步態研究指出，初學步幼兒行走時常呈現較明顯之髌、膝與踝關節屈曲，隨著行走經驗與平衡能力發展，關節屈曲程度逐漸降低、姿態逐漸趨於伸展。因此，本研究將膝關節角大於約 120° 之影格視為較接近直立姿態，該門檻依據幼兒步態特性與本研究資料觀察所設定之操作性條件。




圖 3.5 步態片段篩選之膝關節角度判斷示意圖

3.6.2 骨架投影比例合理性

在骨架結構品質控制方面，本研究進一步檢查單一影格中骨架於 2D 影像平面上之投影比例合理性，以排除因身體相對攝影機角度過大或關鍵點錯置所造成之異常骨架。過去以 2D 姿態估測進行步態分析之研究亦指出，非受控影像環境中可能出現異常偵測與骨架座標錯誤，因此有必要於後續分析前加入骨架品質與結構合理性檢查[60]。由於本研究主要分析正面或背面步行片段，若幼兒身體過度側向於攝影機，左右髖關鍵點於 2D 影像平面上的投影距離可能明顯縮小，進而導致軀幹長度與髖寬之比例異常。基於此，本研究以軀幹長度與髖寬之比值作為骨架投影比例合理性之判斷依據。其中，髖寬定義為左右髖關鍵點之歐氏距離，骨架投影比例表示如下：

$$R_{\text{torso},t} = \frac{L_{\text{torso},t}}{W_{\text{hip},t}} \quad (3.6)$$

$L_{\text{torso},t}$ 表示第 t 幀之軀幹長度， $W_{\text{hip},t}$ 表示第 t 幀之髖寬。當 $R_{\text{torso},t} \leq \tau_{\text{torso}}$ 時，

視為比例合理。本研究設定 $\tau_{torso} = 3.5$ ，作為排除明顯異常骨架比例之經驗性門檻；此數值係依據本研究資料分佈與實驗觀察決定，主要用以移除髖部關鍵點偏移、軀幹尺度異常或姿態估測錯位之影格。




圖 3.6 步態片段篩選之軀幹高度與髖部寬度特徵示意圖

3.6.3 步態交替條件

為確認骨架序列具有穩定之左右步態交替特徵，本研究以左右踝關節之垂直座標差作為主要判定依據。由於左右踝在行走過程中會隨擺盪腳交替而產生週期性高低變化，該訊號可用以反映步態節律。

實作上，先對左右踝垂直差進行中位數中心化，以降低整體位移與個體差異影響，並於訊號中偵測局部峰值與谷值。相鄰峰值與谷值之時間間隔可反映左右腳交替事件之發生頻率，因此本研究進一步根據交替事件間隔估計步頻。當區段中可觀察到至少四次以上之左右交替事件，且其估計步頻落於合理範圍內時，表示該片段具有基本之步態週

期與左右腳交替節律。

然而，僅具備左右腳交替特徵仍不足以保證該片段為穩定步行；例如停頓、拖行、跑步、跳躍，或姿態估測造成之局部震盪，亦可能產生類似的交替訊號。因此，本研究進一步引入步頻作為輔助篩選條件，以排除非穩定步行片段。根據兒童步態發展研究，1 至 3 歲幼兒之步頻通常高於成人，常見約落於 98 – 178 steps/min（約 1.6 – 3.0 steps/s）之區間[61]。因此，本研究採用較寬鬆之步頻範圍作為有效步行判定標準，保留步頻介於 1.5 – 3.5 steps/s 之片段。低於此範圍者，多可能為停頓、非連續移動或不穩定步行；高於此範圍者，則可能對應跑步、跳躍或姿態估測造成之異常高頻震盪。





圖 3.7 左右踝關節垂直位移差之步態交替模式示意圖

3.6.4 有效步態區段建立與片段切割

完成上述條件判定後，本研究僅保留同時滿足直立姿態、骨架投影比例與步態交替條件之連續影格，並整合為最終有效步態區段。

Frame		...		...		...		...	
Frame id	0		34		129		134		165
Upright Posture	✓		✓		✓		✗		✓
In Motion	✗		✓		✓		✗		✓
Facing Front/Back	✓	...	✓	...	✓	...	✓	...	✗
Valid Frame	✗		✓		✓		✗		✗



valid segment
(≥ 96 frames)

圖 3.8 有效步態片段擷取之影格篩選條件示意圖

為統一模型輸入長度，本研究再將有效步態區段切割為固定長度之子序列，僅保留長度完整之片段，不足固定長度之尾段則不納入分析。由於深度學習模型通常需要一致長度之時序資料，若直接輸入長度不一之步態片段，可能增加模型訓練與批次處理之困難。因此，本研究於有效步態區段擷取後，進一步進行固定長度切割處理。

在序列長度設定上，本研究綜合考量步態資訊完整性與資料可用性。一般而言，較短序列雖可提升可用樣本數，但因涵蓋之步態週期數較少，可能不足以完整描述步態動態特徵；相對地，較長序列雖可提供較完整之時序資訊，但在自然場景中較難取得長時間穩定之連續步態區段，可能導致可用資料量下降。因此，本研究選擇 96 幀作為最終輸入長度。該長度約對應 3 秒之時間範圍（以 30 fps 計），可涵蓋多個步態週期，並在步態資訊完整性與資料可用性之間取得平衡。

具體而言，設片段範圍為 $[s, e]$ ，當其長度滿足 $e - s + 1 \geq 96$ 時，則以不重疊方式切割為長度 96 幀之子片段，僅保留長度完整之子序列，不足 96 幀之尾段不納入分析。透過此流程，本研究得以建立長度一致且具代表性之骨架時序資料，作為後續關

節點骨架表示與模型訓練之輸入。

3.7 關節點骨架

本節說明本研究所採用之骨架表示方式與骨架時序模型設計。考量步態成熟度主要反映於軀幹穩定性、下肢支撐與擺盪行為，以及四肢協調之時間動態變化，本研究並未直接使用姿態估測模型輸出之完整 17 個人體關鍵點，而是依據步態分析需求，將其精簡為 8 個主要關鍵點作為骨架表示。後續採用 ResGCN 作為時空圖卷積模型，以擷取步態序列中的空間拓撲關係與時間動態特徵。

3.7.1 關節點骨架表示

姿態估測模型於每一影格中輸出人體 17 個關鍵點座標，包含頭臉部、上肢、軀幹與下肢等部位。考量頭臉部節點如眼、耳、鼻等，與步態動作之關聯性較低，且容易受到視角、遮擋與姿態估測誤差影響；手肘與手腕等遠端上肢節點雖可能反映平衡調節行為，但在居家或臨床自然場景中，也容易受到揮手、扶持、拿取物品或與環境互動等非步態因素干擾。因此，本研究移除上述節點，僅保留左右肩、左右髖、左右膝與左右踝等，與步態密切相關的軀幹及四肢節點，共 8 個二維空間座標作為骨架表示。

在骨架拓撲上，本研究依人體解剖結構定義節點間之連線關係，包括肩部連線、髖部連線、左右下肢鏈結（髖－膝－踝），以及軀幹連線（肩－髖）。此一設計使骨架不僅保留各關節之位置資訊，亦保有人體本身之結構先驗，有利於後續圖卷積模型依循合理之關節相依關係進行特徵學習。

相較於直接使用完整 17 點骨架，8 點骨架表示更聚焦於步態成熟度判別所需之核心身體結構，包括軀幹穩定性、骨盆位置、下肢支撐、膝踝協調與左右下肢交替等資訊。此一簡化表示可在保留主要步態特徵之前提下，降低輸入維度與非關鍵動作變異，使模型更集中學習與幼兒步態發展相關之關節運動模式，進而提升訓練穩定性與泛化能力。




圖 3.9 姿態估測關鍵點篩選與 8 點步態骨架拓模定義示意圖

3.7.2 骨架時空圖表示

為同時建模骨架之空間結構與時間變化，本研究將步態序列表示為時空圖 $G = (V, E)$ 其中， V 表示關節節點集合， E 表示圖中邊集合。邊集合可進一步區分為空間邊與時間邊兩類：空間邊用以描述同一時間點下各關節之解剖連結關係，時間邊則用以連接相鄰時間點中對應之相同關節，以表示骨架序列之時間連續性。

基於此一定義，單一骨架序列不再僅被視為一般向量或單一路徑時序資料，而是同時包含人體拓模結構與跨幀運動資訊之圖形資料。對於步態分析而言，此一表示方式可使模型在學習過程中同時考慮關節間之空間依存關係與動作隨時間的演變，較能貼近人體動作本身之結構特性。

就模型輸入形式而言，單一樣本可表示為：

$$X \in R^{I \times C \times T \times V \times M} \quad (3.7)$$

其中， I 表示輸入分支數， C 表示各分支之通道數， T 表示時間長度， V 表示關節

點數， M 表示畫面中人體數量。於本研究中， $I = 4$ ，對應 joint、velocity、bone 與 acceleration 四種輸入分支； $T = 96$ 表示每段步態片段包含 96 幀； $V = 8$ 表示 8 個骨架關鍵點； $M = 1$ 表示本研究僅考慮單一目標幼兒之骨架序列。各輸入分支皆統一整理為 $C = 6$ 個特徵通道。此處之 C 並非表示影像通道，而是指在單一輸入分支中，每一個關節點於每一時間點所對應之節點特徵維度。換言之，對於任一分支 i 、時間點 t 與關節點 v ，其輸入特徵可表示為一個六維向量，用以描述該關節在該分支下之位置、相對變化或幾何關係等資訊。透過將 joint、velocity、bone 與 acceleration 四種分支皆整理為相同的通道維度，可使不同分支在相同骨架圖結構上進行平行特徵學習，並便於後續特徵串接與圖卷積運算。

3.7.3 多分支骨架輸入設計

過去骨架式動作辨識研究指出，關節座標、骨段向量與運動差分等不同骨架表示可提供互補資訊，因此多分支或多流輸入設計常被用於提升時空動作特徵之表徵能力 [47, 49]。基於此，本研究採用四種骨架特徵分支，分別為關節座標分支 (joint branch)、速度差分分支 (velocity branch)、骨段向量分支 (bone branch) 與加速度差分分支 (acceleration branch)，以從不同角度擷取步態之空間與時間資訊。其中，joint、velocity 與 bone 表示延續骨架式動作辨識中常見之多流特徵設計，而 acceleration 分支則進一步補充二階時間動態資訊，以強化對步態啟動、支撐轉換與動態控制變化之描述。

首先，在 joint 分支中，保留各關節之原始位置資訊，並結合相對於中心關節之位置差異，以描述骨架之整體姿態與局部相對配置。若以 p_t^v 表示第 t 個時間點第 v 個關節之座標，並以中心節點 p_t^c 作為參考，則 joint 分支可表示為：

$$J_t^v = [p_t^v, p_t^v - p_t^c] \quad (3.8)$$

此表示可同時保留關節之空間位置與相對結構資訊，有助於模型捕捉軀幹穩定度、四肢張開型態與左右肢段之相對配置。

其次，velocity 分支用以描述關節於時間序列中的位移變化，即一階時間差分資訊。

其可表示為：

$$V_t^v = p_{t+1}^v - p_t^v \quad (3.9)$$

此分支主要反映關節運動速度與方向變化，對於建模步態節律、左右交替與移動流暢性具有重要作用。相較於僅觀察單幀姿態，velocity 分支更能凸顯步態過程中的動態行為特徵。

再者，bone 分支著重於人體肢段之幾何關係。若令 $\pi(v)$ 表示節點 v 之父節點，則骨段向量可表示為：

$$B_t^v = p_t^v - p_t^{\pi(v)} \quad (3.10)$$

此表示方式可強化關節之間的相對幾何關係，並降低整體平移對特徵之影響。對於步態分析而言，bone 分支有助於描述髖、膝、踝等下肢關節之排列關係與肢段方向變化，進而反映步態姿勢控制與支撐型態。

最後，acceleration 分支用以表達關節運動之二階時間差分，即速度變化率，其可表示為：

$$A_t^v = p_{t+2}^v - 2p_{t+1}^v + p_t^v \quad (3.11)$$

相較於 velocity 分支著重移動速度，acceleration 分支更能反映步態過程中的啟動、減速、重心轉換與支撐切換等較細緻之動態控制資訊，因此可作為步態成熟度判別的重要補充。

上述四種分支於概念上分別對應不同類型之骨架特徵，並於實作中整理為統一之通道表示後輸入模型。此多分支輸入設計可提供彼此互補之時空資訊，使模型得以從靜態姿態、局部幾何與動態變化等不同層面共同學習幼兒步態特徵，提升對步態成熟度差異之表徵能力。




圖 3.10 基於關節、骨向量、速度與加速度特徵之 ResGCN 特徵輸入示意圖

3.8 ResGCN 模型架構設計

本研究採用殘差圖卷積網路 (Residual Graph Convolutional Network, ResGCN) 之精簡化版本作為骨架時序建模模型。作為幼兒步態骨架序列之時空特徵建模模型。整體架構由輸入分支層、主幹特徵融合層與輸出預測層組成。其設計目的在於透過多分支骨架表示分別描述不同層面的步態資訊，並於後續主幹網路中進行跨分支特徵整合，以建構與步態成熟度相關之高階時空表徵。




圖 3.11 多分支 ResGCN 步態發展月齡估計模型架構

於輸入分支層中，本研究分別以 joint、velocity、bone 與 acceleration 四種骨架表示作為模型輸入。各分支輸入彼此獨立且結構相同之圖卷積子網路，每一子網路皆由兩個 ResGCN 模組構成，依序將輸入特徵映射至 64 與 32 個通道。此設計使不同骨架表示可於分支內先行完成低階特徵抽取，分別對應姿態配置、關節位移、骨段方向與動態變化等資訊。

完成各分支特徵抽取後，四個分支之輸出沿通道維度串接，形成 128 通道之融合特徵，並作為主幹特徵融合層之輸入。主幹網路由兩個 AttGCN 模組構成，每一模組包含空間圖卷積（spatial graph convolution, SCN）、時間卷積（temporal convolution, TCN）、

殘差映射與部位注意力機制。另第 l 層特徵表示為 $H^{(l)}$ ，則單一模組之運算概念可表示為：

$$\tilde{H}^{(l)} = \text{TCN}\left(\text{SCN}(H^{(l)}, A)\right) + R(H^{(l)}) \quad (3.12)$$

$$H^{(l+1)} = \text{Att}(\tilde{H}^{(l)}) \quad (3.13)$$

其中， A 為骨架圖之鄰接矩陣， $\text{SCN}(\cdot)$ 用以依據骨架拓樸聚合相鄰關節特徵， $\text{TCN}(\cdot)$ 用以擷取跨時間之步態動態變化， $R(\cdot)$ 為殘差映射，用以保留輸入特徵並改善深層網路之訓練穩定性； $\text{Att}(\cdot)$ 則為部位注意力模組，用以對不同身體部位之特徵貢獻進行加權。

在卷積設定上，本研究於時間維度採用大小為 5 之卷積核，以擷取短時間範圍內之步態節律與動態變化；空間維度之卷積核大小設定為 2，對應於空間圖卷積所使用之鄰接分區數。由於模型建構於前述 8 點骨架圖之上，因此可在保留人體解剖結構先驗之基礎上，同時建模關節間空間依存關係與連續影格間之動態資訊。

於輸出預測層中，主幹網路輸出之高階時空特徵首先經由 global average pooling 轉換為片段層級之全域表示，接著通過 dropout 與全連接層，輸出對應 7 個月齡標籤中心之 logits。最後，模型透過 softmax 函數將 logits 轉換為月齡標籤分佈，並作為後續 Label Distribution Learning 與期望值月齡解碼之基礎。

綜上所述，本研究採用之 ResGCN 架構結合多分支骨架表示、圖拓樸建模、時間動態建模與部位注意力加權機制，可有效擷取幼兒步態序列中與動作成熟度相關之局部與全域時空特徵，並作為後續月齡估計與發展遲緩風險分析之核心模型。

3.9 標籤分佈建模與損失函數設計

本研究之預測目標為幼兒月齡，其本質上具有連續性與發展序列特性。若將月齡視為一般離散分類問題，將難以反映相鄰月齡之間的關係；若僅以單一連續數值進行迴歸，則較難描述不同月齡步態成熟度之重疊與過渡現象。因此，本研究採用標籤分佈學習 (Label Distribution Learning, LDL) 進行月齡建模，將單一月齡標籤轉換為一組具鄰近

關係的機率分佈，以保留月齡發展之連續特性。

3.9.1 月齡標籤中心之設定

為建立標籤分佈表示，本研究依合作臨床醫師之建議，並參考臨床評估量表之分級邏輯，以每三個月作為一個發展區間。考量本研究資料之主要月齡範圍，最終設定 7 個月齡標籤中心如下：

$$B = \{12, 15, 18, 21, 24, 27, 30\} \quad (3.14)$$

其中， B 表示月齡標籤中心集合， b_k 表示第 k 個標籤中心。此設計可兼顧臨床可解釋性與建模穩定性，並避免月齡切分過細導致樣本稀疏。

3.9.2 Gaussian 標籤分佈建模

對於真實月齡 y ，本研究不直接將其視為單一類別，而是根據其在標籤中心序列中的相對位置，轉換為 Gaussian 目標分佈。設 z 為真實月齡 y 在標籤中心序列中的相對位置，則第 k 個標籤中心對應之目標分佈值 q_k 定義為：

$$q_k = \frac{\exp\left(-\frac{(k-z)^2}{2\sigma^2}\right)}{\sum_{j=1}^K \exp\left(-\frac{(j-z)^2}{2\sigma^2}\right)} \quad (3.15)$$

其中， K 為標籤中心總數， σ 為分佈平滑參數，本研究設定 $\sigma = 1$ 。此設計使目標分佈主要集中於真實月齡附近之標籤中心，同時保留相鄰月齡間的平滑過渡關係，以反映幼兒步態發展之漸進特性。

3.9.3 模型輸出與月齡期望值

模型最後會輸出各月齡標籤中心對應之分數，並經 softmax 轉換為預測機率分佈。由於本研究最終目標仍為月齡之連續數值估測，因此於推論階段採用期望值解碼方式，將預測分佈轉換為單一月齡估計值：

$$\hat{y} = \sum_{k=1}^K \hat{p}_k b_k \quad (3.16)$$

其中， $\hat{p}_k$ 表示模型對第 k 個標籤中心之預測機率， $\hat{y}$ 為模型最終預測月齡， b_k 為第 k 個月齡標籤中心。此方式能同時利用整體機率分佈資訊，而非僅取最大機率之單一類別，因此更能保留月齡估測之連續性。

3.9.4 損失函數設計

為使模型輸出之預測分佈 $\hat{p}$ 能夠貼近目標標籤分佈 q ，本研究以 Kullback–Leibler divergence 作為主要損失函數，其定義如下：

$$\mathcal{L}_{KL} = \sum_{k=1}^K q_k \log \left(\frac{q_k}{\hat{p}_k} \right) \quad (3.17)$$

KL divergence 用以衡量兩個機率分佈之差異程度，使模型不僅學習真實月齡附近標籤中心之高機率分配，也能學習相鄰月齡區間之合理衰減關係。因此，本研究所優化者並非單一類別之命中結果，而是整體月齡分佈之擬合程度，以符合幼兒步態成熟度隨月齡逐步發展之特性。

3.10 訓練策略、資料切分與模型設定

為評估本研究所提出之骨架時序建模方法於幼兒步態月齡估測任務中的泛化能力，本研究針對資料切分、資料擴增、訓練流程與模型超參數進行統一設定。本節說明五折交叉驗證之分割原則、訓練資料擴增策略，以及最終採用之訓練設定。

3.10.1 資料切分策略

本研究採用五折交叉驗證（5-fold cross-validation）作為主要訓練與模型評估方式。於每一次實驗中，將正常發展組資料分為五個 fold，取其中一折作為驗證集，其餘四折作為訓練集，並重複進行五次訓練與驗證，使每一個正常組個案皆能在其中一次實驗中

作為驗證資料，以降低單次資料切分所造成之偶然性。

資料切分時，本研究並非以單一骨架片段為分割單位，而是採用個案層級分割。亦即，同一受試者所產生之所有步態片段僅會被分配至同一 fold，以避免同一幼兒之片段同時出現在訓練集與驗證集中，造成資料洩漏。由於同一受試者的多段骨架序列在身形比例、姿態風格與拍攝條件上具有高度相似性，若未採用個案層級分割，模型可能學得個體特徵，而非具泛化性的步態成熟度特徵。

此外，為降低月齡分佈不均對模型訓練與驗證結果之影響，本研究於個案層級切分時進一步考量月齡區間平衡，使各 fold 在月齡範圍與樣本組成上盡可能維持相近分佈。

在正常組驗證階段，每位正常組個案僅於其所屬 fold 中進行驗證，並未參與該次模型訓練。因此，其預測結果可反映模型面對未見個案時的估測能力，用以評估正常發展幼兒步態月齡估測之泛化表現。

另一方面，對於遲緩風險分析，由於遲緩組個案數量相對有限，本研究未將其納入交叉驗證切分，而是使用五個 fold 所訓練出的模型，分別對同一批遲緩組個案進行推論。換言之，每一位遲緩組個案皆會獲得五次預測月齡結果，最後再以五次預測值之平均作為該個案的最終預測月齡。

此作法可降低單一 fold 模型訓練結果所造成之波動，使遲緩組個案之預測結果更為穩定，並作為後續月齡落差、z-score 與遲緩風險判定之依據。

3.10.2 訓練資料擴增策略

為提升模型對拍攝位置微小變動、人體尺度差異及左右方向變化之容忍能力，並降低小樣本資料條件下之過擬合風險，本研究於訓練階段對輸入骨架序列施加隨機資料擴增。考量本研究之輸入為經正規化後之二維骨架時序資料，資料擴增操作須在不破壞人體拓撲結構與步態時間連續性的前提下進行。因此，本研究採用三類幾何增強操作，分別為隨機平移、隨機縮放與水平翻轉。

首先，在隨機平移方面，以機率 0.5 對整段骨架序列施加全域位移。平移量自區間

$[-0.1, 0.1]$ 中均勻取樣，並對同一序列之所有時間點與所有關節施加一致之位移量。以模擬標準化座標系統下可能存在之小幅位置偏移，同時避免逐幀獨立擾動破壞原始步態之時間動態模式。

其次，在隨機縮放方面，以機率 0.5 對整段骨架序列施加一致之比例縮放，其縮放倍率自區間 $[0.95, 1.05]$ 中均勻取樣。此操作用以模擬受試者與攝影機相對距離、拍攝取景及姿態估測結果所造成之輕微尺度差異。由於本研究於前處理階段已進行骨架尺度正規化，因此此處縮放幅度控制於較小範圍內，以避免過度扭曲原始骨架幾何關係。

第三，在水平翻轉方面，以機率 0.5 對骨架序列施加左右鏡像操作。具體而言，翻轉時將所有關節之 x 座標取相反數，並同步交換左右對應之關節索引，以維持骨架拓撲與關節語意之一致性。對於本研究採用之 8 點骨架配置，左右對應關節包含肩、髖、膝與踝等四組對稱關節。由於本研究任務著重於步態成熟度與肢體協調模式，而非個體慣用側辨識，因此適度引入左右鏡像樣本，可降低模型對特定方向偏置之依賴。


綜上所述，本研究之資料擴增策略皆以「整段序列一致變換」為原則，避免破壞骨架時序資料之動作連續性與人體結構合理性。上述擴增操作僅於訓練階段使用，驗證與推論階段則不施加任何隨機變換，以確保模型評估結果之穩定性與可比性。

3.10.3 訓練策略

在模型訓練方面，本研究採用隨機梯度下降法 (Stochastic Gradient Descent, SGD) 作為最佳化器，初始學習率設定為 0.01，動量 (momentum) 設定為 0.9，並使用 Nesterov momentum，以提升參數更新方向之穩定性與收斂效率。權重衰減 (weight decay) 設定為 0.005，以降低模型過度擬合之風險。

在學習率調整策略方面，本研究採用 cosine annealing scheduler，並搭配預熱 (warm-up) 機制。於預熱階段，學習率由較小值逐步增加，以避免訓練初期因參數更新過大而導致不穩定；預熱結束後，則以 cosine 形式逐步衰減學習率，使模型在訓練後期能比較平滑之方式收斂。本研究最大訓練 epoch 設定為 120，預熱階段 epoch 設定為 5。

在批次設定上，訓練批次大小與驗證批次大小皆設定為 32，以兼顧 GPU 記憶體限制與訓練穩定性。在最佳模型選擇上，本研究以驗證集之 KL divergence 最低者作為最佳 epoch，並保存其模型權重用於後續評估與分析。



第四章 實驗結果與分析

4.1 五折交叉驗證之月齡預測表現

本章依據五折交叉驗證輸出結果，分析模型於月齡預測與遲緩風險篩檢之表現。月齡預測能力之評估以正常組所有折之驗證資料集為主，遲緩風險分析則納入正常組與遲緩組個案共同比較。分析內容包括五折交叉驗證之月齡預測表現、不同年齡層之誤差分佈、個案層級預測一致性，以及固定閾值下之遲緩篩檢結果。

表 4.1 五折交叉驗證下發展月齡估計模型之預測表現

Fold	MAE	MSE	RMSE	Pearson	Spearman
1	3.172	14.565	3.816	0.719	0.691
2	2.324	9.715	3.117	0.847	0.853
3	2.607	11.313	3.363	0.817	0.806
4	2.878	13.571	3.684	0.784	0.757
5	2.895	13.947	3.735	0.719	0.747
Mean	2.775	12.622	3.543	0.777	0.771
Std	0.288	1.822	0.263	0.052	0.055

表 4.2 不同組別與月齡區間之有效步態片段數分布

組別	月齡區間	正面片段	背面片段	總片段數
正常組	12-18 個月	56	77	133
	18-24 個月	66	93	159
	24-30 個月	58	69	127
遲緩組	24-30 個月	19	21	40

總計	199	260	459
----	-----	-----	-----

表 4.3 片段層級與個案層級之預測表現比較

評估層級	樣本數	MAE	RMSE	Pearson	Spearman
片段層級	419 片段	2.775	3.556	0.771	0.773
個案層級	159 個案	2.794	3.543	0.803	0.802

4.1.1 步態片段層級結果

本研究首先於步態片段層級評估模型之月齡預測能力。五折交叉驗證共評估 416 個步態片段，各折最佳模型之平均絕對誤差 (MAE) 介於 2.32 至 3.17 個月之間，整體平均 MAE 為 2.78 個月，平均均方誤差 (MSE) 為 12.62，對應之均方根誤差 (RMSE) 約為 3.56 個月；平均 Spearman 相關係數為 0.771。顯示模型於單一片段層級已具備中高度之月齡辨識能力。此外，63.0% 的步態片段預測誤差小於 3 個月，90.9% 小於 6 個月，顯示模型在步態片段上已能提供具有實用性的月齡估計結果。

表 4-1 建議標題：五折交叉驗證之 Segment-level 月齡預測表現




圖 4.1 Segment-level 預測月齡與真實月齡散點圖

4.1.2 個案層級結果

考量臨床應用情境通常以個案為主要判讀單位，本研究進一步將同一個案之多個片段預測值取平均，形成個案層級月齡預測結果。於 159 個正常組資料中，個案層級 MAE 為 2.79 個月，RMSE 為 3.54 個月，Pearson 相關係數為 0.803，均優於片段層級結果。另有 64.8% 的 cases 預測誤差小於 3 個月，92.5% 小於 6 個月。整體平均誤差為 -0.62 個月。此結果顯示，模型可由正常發展幼兒之步態骨架序列中擷取與月齡相關之成熟度訊號，並支持後續以個案層級作為主要分析單位。

由於臨床判讀通常以個案為單位，而非單一短片段為單位，本研究進一步檢視同一個案多段片段預測結果之一致性。在正常組 159 個案中，共有 112 個案具有至少兩段有效片段，其片段間預測範圍以最大預測月齡與最小預測月齡之差定義，平均為 2.46 個月，中位數為 2.02 個月。此結果顯示，模型對同一個案不同步態片段之預測具有一定程度之一致性。相較於單一片段預測，個案層級聚合可降低片段擷取、短暫姿態變化或骨架估測波動所造成之偶然誤差，因此更適合作為後續月齡預測與遲緩風險指標分析之主要單位。

由個案平均之散點分佈可見，預測月齡與真實月齡整體呈現正相關關係，證明模型確實具備擷取發展相關步態訊息的能力。如圖 4-1 所示，多數正常組個案之預測點分佈仍圍繞於理想線附近，但於高月齡區間可觀察到逐漸偏向低估之趨勢。

表 4.2 Segment-level 與 Case-level 表現比較




圖 4.2：Case-level 真實月齡與預測月齡散點圖

4.2 月齡分級表現與年齡層誤差分佈

為進一步了解模型誤差是否與年齡層相關，本研究將正常組 case 依真實月齡分為 12 - 18 月、18 - 24 月與 24 - 30 月三組，分析其 case-level 預測誤差分佈。如圖 4-2 所示，12 - 18 月組之平均誤差為 $+2.11 \pm 2.28$ 個月，顯示模型對低月齡個案有明顯高估傾向；18 - 24 月組之平均誤差為 -0.36 ± 2.89 個月，已接近無偏；24 - 30 月組之平均誤差則為 -3.44 ± 2.71 個月，顯示模型對高月齡個案存在穩定的低估趨勢。

若觀察更細部的真實月齡分佈，可發現 12 月個案平均被高估約 3.90 個月，而 30 月個案平均被低估約 4.39 個月，表示模型誤差並非隨機，而是沿月齡軸呈現方向一致

之系統性偏移。此結果顯示，模型雖能辨識發展程度的大致順序，但在年齡尺度上存在朝整體平均值回縮的現象。




圖 4.3 不同真實月齡區間之 Case-level 預測誤差分佈

4.3 遲緩風險指標分析

4.3.1 方向性預測誤差 z-score 之定義

為將模型之月齡預測結果轉換為發展遲緩風險指標，本研究採用方向性預測誤差作為主要分析依據。對於第 i 個 case，定義其預測誤差為模型預測月齡與實際月齡之差：

$$e_i = \hat{y}_i - y_i \quad (4.1)$$

$\hat{y}_i$ 表示模型預測之步態發展月齡， y_i 表示個案之實際月齡。當 $e_i < 0$ 時，代表模型預測之步態發展月齡低於實際月齡，亦即其步態表現相對於年齡期待可能較為落後；反之，當 $e_i > 0$ 時，則表示預測步態發展月齡高於實際月齡。為使不同個案之預測誤差可相對於正常發展組之分佈進行比較，本研究進一步以個案層級正常組預測誤差之平均值與標準差建立標準化分數：

$$z_i = \frac{e_i - \mu_{\text{normal}}}{\sigma_{\text{normal}}} \quad (4.2)$$

其中， μ_{normal} 與 σ_{normal} 分別表示正常發展組預測誤差之平均值與標準差。由於本研究之篩檢目標為辨識預測月齡明顯低於實際月齡之個案，因此 z_i 數值越低，代表其步態發展月齡相對實際月齡越落後，發展遲緩風險越高。於 ROC 分析中，本研究進一步以 $-z_i$ 作為風險分數，使分數越高表示遲緩風險越高。

4.3.2 24 個月以上樣本之 ROC 分析

由於本研究之發展遲緩個案皆分佈於 24 個月以上，若直接以整體樣本進行 ROC 分析，結果可能同時受到正常發展組與遲緩組之年齡分佈差異影響。為使發展遲緩風險分析更聚焦於具有可比性的年齡範圍，本研究首先限制分析對象為實際月齡 24 個月以上之個案，並以方向性預測誤差 z-score 評估模型對發展遲緩風險之區辨能力。

本研究定義之方向性預測誤差 z-score 越低，代表模型預測月齡相對於實際月齡越低，亦即個案之步態成熟度可能落後於其實際發展年齡。因此，在 ROC 分析中，本研究以 $-z_i$ 作為風險分數，使分數越高代表越高之發展遲緩風險。

在 24 個月以上樣本中，共包含 55 個正常發展 case 與 19 個發展遲緩 case。ROC 分析結果顯示，方向性預測誤差 z-score 於此年齡範圍內仍具有良好區辨能力，AUC 為 0.979。此結果顯示，即使僅於較高月齡樣本中比較，模型仍能透過「預測月齡是否明顯低於實際月齡」辨識出多數遲緩個案，支持該指標作為發展遲緩風險篩檢依據之可行性。

因此，24 個月以上樣本之 ROC 結果較能反映本研究模型於實際發展遲緩風險族群中的判別能力，亦可作為本研究後續風險分析之主要依據。




圖 4.4 24 個月以上樣本之方向性預測誤差 z-score ROC 曲線

4.3.3 整體樣本之 ROC 分析

除針對 24 個月以上樣本進行主要分析外，本研究亦進一步於整體樣本中評估方向性預測誤差 z-score 對發展遲緩風險之區辨能力，以作為補充驗證。整體樣本包含 159 個正常發展 case 與 19 個發展遲緩 case，共 178 個 case。

與前述分析相同，由於本研究定義之 z_i 越低代表越高之發展遲緩風險，因此 ROC 分析時同樣以 $-z_i$ 作為風險分數。整體樣本之 ROC 分析結果顯示，方向性預測誤差 z-score 可有效區分正常發展組與發展遲緩組，AUC 為 0.989。

此結果顯示，模型所輸出之預測月齡與實際月齡之差異，並非僅為一般預測誤差，而可進一步反映個案步態成熟度是否相對落後於其實際月齡。整體樣本之 AUC 略高於 24 個月以上樣本，可能與納入較低月齡之正常發展個案後，整體組間分佈差異較為明顯有關。因此，本研究將整體樣本 ROC 結果視為補充分析，用以支持方向性預測誤差 z-score 作為發展遲緩風險指標之潛力；而主要風險判別結果則仍以 24 個月以上樣本分析為主。




圖 4.5 整體樣本之方向性預測誤差 z-score ROC 曲線

4.4 固定閾值篩檢結果

4.4.1 閾值設定原則

本研究之固定閾值篩檢採用方向性預測誤差 z-score。基於本研究之篩檢目的為辨識預測月齡明顯低於實際月齡之個案，因此採用單側閾值 $z\text{-score} < -1.96$ 作為遲緩判定標準。換言之，若個案之方向性誤差 z-score 低於 -1.96，表示其模型預測之步態發展月齡明顯低於實際月齡，且相較於正常發展組已落於較極端之低估區間，因此判定為具有較高發展遲緩風險。此方法可將模型之月齡預測結果轉換為具方向性與標準化意義之風險指標，並作為後續固定閾值篩檢分析之依據。

4.4.2 24 個月以上樣本之固定閾值篩檢結果

由於本研究之遲緩組個案皆分佈於 24 個月以上，因此本節首先針對 24 個月以上樣本進行主要分析。此子樣本共納入 74 例個案，其中正常發展組 55 例，發展遲緩組 19 例。當以月齡區間校正後之方向性誤差 $z\text{-score} < -1.96$ 作為固定閾值時，混淆矩陣結果顯示，真陰性為 51 例、偽陽性為 4 例、偽陰性為 3 例、真陽性為 16 例。

根據上述結果計算，各項篩檢指標如下：敏感度為 0.842，表示 19 例遲緩個案中有 16 例可被正確辨識；特異度為 0.927，表示多數正常發展個案可被正確排除。陽性預測值為 0.800，陰性預測值為 0.944，整體準確率為 0.905。此結果顯示，在 24 個月以上之高風險年齡區間中，固定閾值法能夠維持良好的正常排除能力，同時辨識大多數發展遲緩個案，顯示其具備作為臨床前篩工具之潛力。

表 4. 整體樣本之遲緩風險辨識結果與 95% 信賴區間

指標	估計值	95% CI
AUC	0.989	0.975-0.998
Sensitivity	84.21%	68.42%-99.18%
Specificity	97.48%	94.97%-99.37%
F1	82.05%	68.42%-92.68%
Accuracy	90.54%	83.78%-97.30%




圖 4.6 24 個月以上樣本之固定閾值遲緩篩檢混淆矩陣

表 4.4 不同關節點組合於 24-30 個月子群之遲緩風險分辨結果

關節組合	使用關節	AUC	Sensitivity	Specificity
下肢關節組	髖、膝、踝	0.946	0.632	0.946
肩與下肢關節組	肩、髖、膝、踝	0.979	0.842	0.927
上下肢關節組	肩、肘、腕、髖、膝、踝	0.488	0.000	0.964

4.4.3 整體樣本之補充分析

為進一步檢視固定閾值法於全體資料中的表現，本研究亦將全部 178 例個案納入補充分析。其中，正常發展組為 159 例，發展遲緩組為 19 例。以相同之月齡區間校正後方向性誤差 $z\text{-score} < -1.96$ 作為判定標準時，混淆矩陣結果為：真陰性 155 例、偽陽性 4 例、偽陰性 3 例、真陽性 16 例。

如表 4.X 所示，方向性誤差風險分數於整體樣本中達到 $AUC = 0.989$ ，95% 信賴區間為 0.975 至 0.998，顯示該指標具有良好的正常發展與發展遲緩個案區辨能力。在固定閾值判定下，模型之敏感度為 84.21%，特異度為 97.48%，F1-score 為 82.05%，

整體準確率為 96.07%。其中，特異度之 95% 信賴區間為 94.97% 至 99.37%，顯示模型對正常發展個案具有穩定的排除能力；敏感度之 95% 信賴區間則為 68.42% 至 99.18%，反映發展遲緩組樣本數有限時，敏感度估計仍存在較大的不確定性。

整體而言，個案層級信賴區間分析支持方向性預測誤差 z-score 可作為發展遲緩風險輔助篩檢指標。然而，由於本研究發展遲緩組樣本數僅 19 位，敏感度與陽性預測值之信賴區間相對較寬，因此本結果應解讀為模型具備發展遲緩風險辨識潛力，而非作為單獨診斷依據。後續仍需納入更多發展遲緩個案與外部資料集，以進一步驗證模型於不同族群與自然場域下之穩定性。

然而，由於本研究之遲緩個案全數分佈於 24 個月以上，且高月齡正常組本身較容易受到模型低估偏差之影響，因此整體樣本結果可能受到大量低月齡正常個案影響，而呈現較高的特異度與準確率。基於此，本研究仍以 24 個月以上樣本之篩檢結果作為主要分析，整體樣本結果則作為補充佐證。此安排較能反映模型在實際發展遲緩風險情境下之應用價值。

表 4. 整體樣本之遲緩風險辨識結果與 95% 信賴區間

指標	估計值	95% CI
AUC	0.989	0.975-0.998
Sensitivity	84.21%	68.42%-99.18%
Specificity	97.48%	94.97%-99.37%
F1	82.05%	68.42%-92.68%
Accuracy	96.07%	93.26%-98.31%




圖 4.8 整體樣本之固定閾值遲緩篩檢混淆矩陣



第五章 結論與未來研究

5.1 研究結論與貢獻

本研究針對嬰幼兒發展遲緩早期篩檢之需求，建立一套以自然步態影片為基礎之步態發展輔助評估流程。研究資料來自一般智慧型手機拍攝之幼兒正面或背面自然行走影片，並透過姿態估測、多目標追蹤、目標幼兒軌跡辨識、骨架正規化與有效步態片段擷取，將原始影片轉換為可供模型分析之骨架時序資料。此流程使自然場景中拍攝之幼兒步態影片得以被量化分析，為後續發展輔助評估提供資料基礎。

在模型建構方面，本研究以與步態動作較相關之骨架關節作為輸入，並採用圖卷積神經網路進行骨架時序特徵建模。考量幼兒月齡具有連續性與相鄰月齡間之發展過渡特性，本研究進一步採用 Label Distribution Learning 進行月齡標籤建模，使模型輸出可轉換為連續形式之步態發展月齡。研究結果顯示，模型預測之步態發展月齡與實際月齡之間具有一定關聯，表示幼兒行走過程中的關節位置變化、身體協調與步態節律，可能包含與動作成熟度相關之資訊。

此外，本研究將預測步態發展月齡與實際月齡進行比較，並以方向性預測誤差 z -score 分析其作為發展遲緩風險輔助指標之可行性。若幼兒之預測月齡明顯低於其實際月齡，代表其步態成熟度可能相對落後。結果顯示，此指標具有區分正常發展組與發展遲緩組之潛力，提供一種由連續步態發展月齡估計延伸至遲緩風險分析的可行方向。

整體而言，本研究之主要貢獻在於建立由自然步態影片、骨架時序建模至發展風險分析之完整流程，並初步驗證自然步態影片結合骨架分析應用於嬰幼兒發展輔助評估之潛力。然而，本研究結果仍應定位為臨床判讀前之輔助參考，而非取代專業診斷。

5.2 研究限制

本研究仍存在若干限制。首先，發展遲緩組個案數量相對有限，且主要集中於 24 個月以上，因此模型於較低月齡遲緩風險個案之辨識能力尚未能充分驗證。雖然本研究

以發展遲緩組作為外部風險分析資料，並透過多個模型推論結果之平均降低單一模型波動，但相關結果仍需更大規模且年齡分佈更完整之資料進一步確認。

此外，本研究採用二維姿態估測作為骨架資料來源，因此仍會受到拍攝角度、身體轉向、遮擋、光線條件與關鍵點估測誤差影響。二維骨架亦無法完整描述深度方向、實際步幅與關節旋轉等三維步態資訊。最後，模型預測結果仍可觀察到一定程度之年齡偏移或壓縮現象，表示模型雖能反映部分月齡相關趨勢，但對完整發展尺度之對應仍有改善空間。

5.3 未來研究方向

未來研究可從資料擴充、方法驗證與臨床應用三方面持續推進。首先，應持續蒐集更多不同月齡層之正常發展與發展遲緩幼兒資料，尤其是 12 至 24 個月之早期遲緩風險個案，以驗證本研究方法是否能應用於更早期之篩檢情境。同時，若能納入不同發展遲緩類型與臨床評估結果，將有助於進一步分析模型對不同發展狀態之敏感度。

其次，未來可針對本研究中各項方法設計進行更完整之消融實驗與模型比較。例如，可比較不同關節點組合、不同片段長度、不同步態片段擷取條件、不同骨架時序模型，以及不同月齡標籤建模方式對預測結果之影響。透過此類實驗，可更明確釐清各模組對模型表現之貢獻，並進一步改善年齡預測偏移與模型泛化能力。

最後，未來可將步態影片分析結果與臨床量表、醫師評估結果或長期追蹤資料結合，建立更完整之多模態發展評估架構。若能追蹤同一幼兒於不同時間點之步態變化，將有助於觀察其發展趨勢，並評估模型於早期介入追蹤與社區篩檢情境中的實際應用價值。

參考文獻

1. Global Research on Developmental Disabilities Collaborators, “Developmental disabilities among children younger than 5 years in 195 countries and territories, 1990–2016: A systematic analysis for the Global Burden of Disease Study 2016,” *Lancet Glob. Health*, vol. 6, no. 10, pp. e1100–e1121, Oct. 2018, doi: 10.1016/S2214-109X(18)30309-7.
2. L.-P. Ho and Y.-C. Lee, “Prevalence of developmental delay among children: A national study based on administrative database of the single-payer National Health Insurance System in Taiwan,” *Child Care Health Dev.*, vol. 48, no. 2, pp. 324–335, Mar. 2022, doi: 10.1111/cch.12932.
3. M. J. Guralnick, “Why early intervention works: A systems perspective,” *Infants Young Child.*, vol. 24, no. 1, pp. 6–28, Jan./Mar. 2011, doi: 10.1097/IYC.0b013e3182002cfe.
4. World Health Organization and United Nations Children’s Fund (UNICEF), *Early Childhood Development and Disability: A Discussion Paper*. Geneva, Switzerland: World Health Organization, 2012.
5. K. E. Adolph and S. R. Robinson, “Motor development,” in *Handbook of Child Psychology and Developmental Science*, vol. 2, 7th ed., L. S. Liben, U. Müller, and R. M. Lerner, Eds. Hoboken, NJ, USA: John Wiley & Sons, 2015, pp. 113–157, doi: 10.1002/9781118963418.childpsy204.
6. A. Chałupka-Borowska and M. Sobieska, “Peabody Developmental Motor Scales—Second Edition: A reliable tool for assessing motor development in children,” *J. Clin. Med.*, vol. 14, no. 24, Art. no. 8936, 2025, doi: 10.3390/jcm14248936.
7. M. C. Piper, L. E. Pinnell, J. Darrah, T. Maguire, and P. J. Byrne, “Construction and validation of the Alberta Infant Motor Scale (AIMS),” *Can. J. Public Health*, vol. 83, suppl. 2, pp. S46–S50, 1992.

8. M. R. Folio and R. R. Fewell, Peabody Developmental Motor Scales, 2nd ed. Austin, TX, USA: PRO-ED, 2000.
9. N. Bayley and G. P. Aylward, Bayley Scales of Infant and Toddler Development: Technical Manual, 4th ed. Bloomington, MN, USA: NCS Pearson, 2019.
10. W. Deng, M. K. O'Brien, R. A. Andersen, R. Rai, E. Jones, and A. Jayaraman, "A systematic review of portable technologies for the early assessment of motor development in infants," *npj Digital Medicine*, vol. 8, Art. no. 63, 2025, doi: 10.1038/s41746-025-01450-3.
11. S. Mohammadi Moghadam, P. Ortega Auriol, T. Yeung, and J. Choisne, "3D gait analysis in children using wearable sensors: feasibility of predicting joint kinematics and kinetics with personalized machine learning models and inertial measurement units," *Frontiers in Bioengineering and Biotechnology*, vol. 12, Art. no. 1372669, 2024, doi: 10.3389/fbioe.2024.1372669.
12. M. Airaksinen et al., "Intelligent wearable allows out-of-the-lab tracking of developing motor abilities in infants," *Communications Medicine*, vol. 2, Art. no. 69, 2022, doi: 10.1038/s43856-022-00131-6.
13. M. S. Abrishami, L. Nocera, M. Mert, I. A. Trujillo-Priego, S. Purushotham, and B. A. Smith, "Identification of developmental delay in infants using wearable sensors: Full-day leg movement statistical feature analysis," *IEEE Journal of Translational Engineering in Health and Medicine*, vol. 7, 2019, doi: 10.1109/JTEHM.2019.2893223.
14. M. Boonzaaijer, F. van Wesel, J. Nuysink, M. J. M. Volman, and M. J. Jongmans, "A home-video method to assess infant gross motor development: Parent perspectives on feasibility," *BMC Pediatrics*, vol. 19, no. 1, p. 392, 2019.
15. C. Chambers, N. Seethapathi, R. Saluja, H. Loeb, S. R. Pierce, D. K. Bogen, L. Prosser, M. J. Johnson, and K. P. Kording, "Computer vision to automatically assess infant

- neuromotor risk,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 28, no. 11, pp. 2431–2442, 2020.
16. D. Groos, L. Adde, R. Støen, H. Ramampiaro, and E. A. F. Ihlen, “Towards human-level performance on automatic pose estimation of infant spontaneous movements,” *Computerized Medical Imaging and Graphics*, vol. 95, p. 102012, 2022.
 17. Y.-Z. Yang, J.-A. Tsai, Y.-L. Yu, M. H.-J. Ko, H.-Y. Chiou, T.-W. Pai, and H.-J. Chen, “Automatic movement recognition for evaluating the gross motor development of infants,” *Children*, vol. 12, no. 3, Art. no. 310, Feb. 2025, doi: 10.3390/children12030310.
 18. J. Pigueiras-del-Real, L. C. Gontard, I. Benavente-Fernández, S. T. Hussain, S. A. Hussain, S. P. Lubián-López, and A. Ruiz-Zafra, “Evaluating non-invasive computer vision-based quantification of neonatal movement as a marker of development in preterm infants: A pilot study,” *Healthcare*, vol. 13, no. 13, p. 1577, 2025.
 19. J. T. Anderson, J. Stenum, R. T. Roemmich, and R. B. Wilson, “Validation of markerless video-based gait analysis using pose estimation in toddlers with and without neurodevelopmental disorders,” *Frontiers in Digital Health*, 2025.
 20. Y. Makihara, M. Okumura, H. Iwama, and Y. Yagi, “Gait-based age estimation using a whole-generation gait database,” in *Proc. 2011 Int. Joint Conf. Biometrics (IJCB)*, 2011, pp. 1–6, doi: 10.1109/IJCB.2011.6117531.
 21. A. H. Dewolf, F. Sylos-Labini, G. Cappellini, F. Lacquaniti, and Y. Ivanenko, “Emergence of different gaits in infancy: Relationship between developing neural circuitries and changing biomechanics,” *Front. Bioeng. Biotechnol.*, vol. 8, Art. no. 473, May 2020, doi: 10.3389/fbioe.2020.00473.
 22. W. Liu, Q. Mei, P. Yu, Z. Gao, Q. Hu, G. Fekete, B. István, and Y. Gu, “Biomechanical characteristics of the typically developing toddler gait: A narrative review,” *Children*, vol. 9, no. 3, Art. no. 406, Mar. 2022, doi: 10.3390/children9030406.

23. C. Tsuyuki, H. Hiraga, M. Sudo, T. Ueda, K. Seo, M. Minatozaki, Y. Fukuda, Y. Okuda, H. Iwasaki, H. Naito, and D. Lu, “Estimability study on the age of toddlers’ gait development based on gait parameters,” *Sci. Rep.*, vol. 13, no. 1, Art. no. 2958, Feb. 2023, doi: 10.1038/s41598-023-30039-7.
24. J.-A. Tsai, Automatic Classification of Toddler Gross Motor Development Based on Gait Feature Analysis, M.S. thesis, National Taipei University of Technology, Taipei, Taiwan, 2025.
25. P.-Y. Huang, Automatic Analysis of Gross Motor Development in Toddlers Using Side-View Walking Pose Estimation, M.S. thesis, National Taipei University of Technology, Taipei, Taiwan, 2025.
26. Z. Cao, T. Simon, S.-E. Wei, and Y. Sheikh, “Realtime multi-person 2D pose estimation using part affinity fields,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 7291–7299, doi: 10.1109/CVPR.2017.143.
27. K. Sun, B. Xiao, D. Liu, and J. Wang, “Deep high-resolution representation learning for human pose estimation,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 5686–5696, doi: 10.1109/CVPR.2019.00584.
28. S. Kreiss, L. Bertoni, and A. Alahi, “OpenPifPaf: Composite fields for semantic keypoint detection and spatio-temporal association,” *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 8, pp. 13498–13511, 2022, doi: 10.1109/TITS.2021.3124981.
29. T. Jiang, P. Lu, L. Zhang, N. Ma, R. Han, C. Lyu, Y. Li, and K. Chen, “RTMPose: Real-time multi-person pose estimation based on MMPose,” *arXiv preprint arXiv:2303.07399*, 2023, doi: 10.48550/arXiv.2303.07399.
30. P. Lu, T. Jiang, Y. Li, X. Li, K. Chen, and W. Yang, “RTMO: Towards high-performance one-stage real-time multi-person pose estimation,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024, pp. 1491–1500, doi: 10.1109/CVPR52733.2024.00148.

31. A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft, "Simple online and realtime tracking," in Proc. IEEE Int. Conf. Image Process. (ICIP), 2016, pp. 3464–3468, doi: 10.1109/ICIP.2016.7533003.
32. N. Wojke, A. Bewley, and D. Paulus, "Simple online and realtime tracking with a deep association metric," in Proc. IEEE Int. Conf. Image Process. (ICIP), 2017, pp. 3645–3649, doi: 10.1109/ICIP.2017.8296962.
33. Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, "ByteTrack: Multi-object tracking by associating every detection box," in Computer Vision – ECCV 2022, Lecture Notes in Computer Science, vol. 13682, S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, and T. Hassner, Eds. Cham, Switzerland: Springer, 2022, pp. 1–21, doi: 10.1007/978-3-031-20047-2_1.
34. N. Aharon, R. Orfaig, and B.-Z. Bobrovsky, "BoT-SORT: Robust associations multi-pedestrian tracking," arXiv preprint arXiv:2206.14651, 2022, doi: 10.48550/arXiv.2206.14651.
35. S. Yu, D. Tan, and T. Tan, "Modelling the effect of view angle variation on appearance-based gait recognition," in Computer Vision – ACCV 2006, Lecture Notes in Computer Science, vol. 3851, P. J. Narayanan, S. K. Nayar, and H.-Y. Shum, Eds. Berlin, Germany: Springer, 2006, pp. 807–816, doi: 10.1007/11612032_81.
36. N. Takemura, Y. Makihara, D. Muramatsu, T. Echigo, and Y. Yagi, "Multi-view large population gait dataset and its performance evaluation for cross-view gait recognition," IPSJ Trans. Comput. Vis. Appl., vol. 10, Art. no. 4, 2018, doi: 10.1186/s41074-018-0039-6.
37. T. B. Aderinola, T. Connie, T. S. Ong, A. B. J. Teoh, and M. K. O. Goh, "Gait-based age group classification with adaptive Graph Neural Network," Eng. Appl. Artif. Intell., vol. 137, pt. A, Art. no. 109081, Nov. 2024, doi: 10.1016/j.engappai.2024.109081.

38. Z. Zhu, X. Guo, T. Yang, J. Huang, J. Deng, G. Huang, D. Du, J. Lu, and J. Zhou, "Gait recognition in the wild: A benchmark," in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2021, pp. 14789–14799, doi: 10.1109/ICCV48922.2021.01452.
39. A. Catruna, A. Cosma, and E. Radoi, "GaitPT: Skeletons are all you need for gait recognition," in Proc. 18th IEEE Int. Conf. Autom. Face Gesture Recognit. (FG), Istanbul, Turkey, 2024, pp. 1–10, doi: 10.1109/FG59268.2024.10581947.
40. Y. Peng, K. Ma, Y. Zhang, and Z. He, "Learning rich features for gait recognition by integrating skeletons and silhouettes," *Multimedia Tools Appl.*, vol. 83, no. 3, pp. 7273–7294, 2024, doi: 10.1007/s11042-023-15483-x.
41. X. Liu, Z. You, Y. He, S. Bi, and J. Wang, "Symmetry-driven hyper feature GCN for skeleton-based gait recognition," *Pattern Recognit.*, vol. 125, Art. no. 108520, May 2022, doi: 10.1016/j.patcog.2022.108520.
42. N. Li and X. Zhao, "A strong and robust skeleton-based gait recognition method with gait periodicity priors," *IEEE Trans. Multimedia*, vol. 25, pp. 3046–3058, 2023, doi: 10.1109/TMM.2022.3154609.
43. H. Tian, X. Ma, H. Wu, and Y. Li, "Skeleton-based abnormal gait recognition with spatio-temporal attention enhanced gait-structural graph convolutional networks," *Neurocomputing*, vol. 473, pp. 116–126, Feb. 2022, doi: 10.1016/j.neucom.2021.12.004.
44. T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in Proc. 5th Int. Conf. Learn. Represent. (ICLR), 2017, doi: 10.48550/arXiv.1609.02907.
45. M. Defferrard, X. Bresson, and P. Vandergheynst, "Convolutional neural networks on graphs with fast localized spectral filtering," in Proc. Adv. Neural Inf. Process. Syst. 29 (NIPS), 2016, pp. 3844–3852, doi: 10.48550/arXiv.1606.09375.
46. S. Yan, Y. Xiong, and D. Lin, "Spatial temporal graph convolutional networks for skeleton-

- based action recognition,” in Proc. 32nd AAAI Conf. Artif. Intell. (AAAI), 2018, pp. 7444–7452, doi: 10.1609/aaai.v32i1.12328.
47. L. Shi, Y. Zhang, J. Cheng, and H. Lu, “Two-stream adaptive graph convolutional networks for skeleton-based action recognition,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 12026–12035, doi: 10.1109/CVPR.2019.01230.
48. Y. Chen, Z. Zhang, C. Yuan, B. Li, Y. Deng, and W. Hu, “Channel-wise topology refinement graph convolution for skeleton-based action recognition,” in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2021, pp. 13359–13368, doi: 10.1109/ICCV48922.2021.01311.
49. Y.-F. Song, Z. Zhang, C. Shan, and L. Wang, “Stronger, Faster and More Explainable: A Graph Convolutional Baseline for Skeleton-based Action Recognition,” in Proc. 28th ACM Int. Conf. Multimedia (MM ’20), 2020, pp. 1625–1633, doi: 10.1145/3394171.3413802.
50. K. Wang, H. Deng, and Q. Zhu, “Lightweight channel-topology based adaptive graph convolutional network for skeleton-based action recognition,” *Neurocomputing*, vol. 560, Art. no. 126830, Dec. 2023, doi: 10.1016/j.neucom.2023.126830.
51. K. Zantvoort, B. Nacke, D. Görlich, S. Hornstein, C. Jacobi, and B. Funk, “Estimation of minimal data sets sizes for machine learning predictions in digital mental health interventions,” *npj Digital Medicine*, vol. 7, Art. no. 361, Dec. 2024, doi: 10.1038/s41746-024-01360-w.
52. S. Wang, H. Cui, T. Tang, L. Zhang, J. Li, M. Wu, and Y. Hou, “Key points of development of motor skills in childhood embodied in gait parameters,” *Gait & Posture*, vol. 104, pp. 51–57, Jul. 2023, doi: 10.1016/j.gaitpost.2023.06.001.
53. Z. Yin, Y. Jiang, J. Zheng, and H. Yu, “STJA-GCN: A multi-branch spatial–temporal joint attention graph convolutional network for abnormal gait recognition,” *Applied Sciences*,

- vol. 13, no. 7, Art. no. 4205, Mar. 2023, doi: 10.3390/app13074205.
54. R. Rothe, R. Timofte, and L. Van Gool, “DEX: Deep EXpectation of apparent age from a single image,” in Proc. IEEE Int. Conf. Comput. Vis. Workshops (ICCVW), 2015, pp. 10–15, doi: 10.1109/ICCVW.2015.41.
 55. X. Geng, “Label distribution learning,” IEEE Trans. Knowl. Data Eng., vol. 28, no. 7, pp. 1734–1748, Jul. 2016, doi: 10.1109/TKDE.2016.2545658.
 56. X. Geng, C. Yin, and Z.-H. Zhou, “Facial age estimation by learning from label distributions,” IEEE Trans. Pattern Anal. Mach. Intell., vol. 35, no. 10, pp. 2401–2412, Oct. 2013, doi: 10.1109/TPAMI.2013.51.
 57. B.-B. Gao, C. Xing, C.-W. Xie, J. Wu, and X. Geng, “Deep label distribution learning with label ambiguity,” IEEE Trans. Image Process., vol. 26, no. 6, pp. 2825–2838, Jun. 2017, doi: 10.1109/TIP.2017.2678998.
 58. P. J. Accardo and A. J. Capute, The Capute Scales: Cognitive Adaptive Test/Clinical Linguistic & Auditory Milestone Scale (CAT/CLAMS). Baltimore, MD, USA: Paul H. Brookes Publishing, 2005.
 59. A. N. Aldosari and T. S. Aldosari, "Comprehensive evaluation of the child with global developmental delays or intellectual disability," Clin. Exp. Pediatr., vol. 67, no. 9, pp. 435–446, Sep. 2024, doi: 10.3345/cep.2023.01697.
 60. Y. Sugiyama, K. Uno, and Y. Matsui, "Types of anomalies in two-dimensional video-based gait analysis in uncontrolled environments," PLoS Comput. Biol., vol. 19, no. 1, p. e1009989, Jan. 2023, doi: 10.1371/journal.pcbi.1009989.
 61. J. Marencakova, C. Price, T. Maly, F. Zahalka, and C. Nester, “How do novice and improver walkers move in their home environments? An open-sourced infant’s gait video analysis,” *PLOS ONE*, vol. 14, no. 6, Art. no. e0218665, Jun. 2019, doi: 10.1371/journal.pone.0218665.

