

基於正、背面步態影片與圖卷積網路之嬰幼兒步態發展輔助評估方法

An Infant Gait Development Assistance Assessment Method Based on Frontal and Rear Gait Videos and Graph Convolutional Networks

古雲鄉

摘要Abstract

本研究提出一套基於正、背面步態影片之嬰幼兒步態發展輔助評估方法。透過 RTMO 與 BoT-SORT 擷取骨架序列，並結合圖卷積網路與標籤分布學習進行月齡估測。研究收集 140 位 12 至 36 個月嬰幼兒資料，其中 130 位正常個案進行受試者獨立五折交叉驗證，10 位遲緩個案作探索性分析。結果顯示模型之均方誤差為 23.956 ± 7.158 ，斯皮爾曼等級相關係數為 0.735 ± 0.136 ，顯示模型可自步態骨架序列中學習與月齡相關之發展特徵。進一步觀察發現，部分遲緩個案於較高月齡區間呈現負向預測偏差，顯示預測偏差具有作為發展風險輔助觀察線索之潛力。

關鍵詞Keywords：

步態分析、圖卷積網路、標籤分布學習、嬰幼兒發展、姿態估測

古雲鄉 0625sean@gmail.com

壹、緒論

嬰幼兒發展遲緩 (developmental delay) 係指兒童在粗大動作、精細動作、語言、認知或社會情緒等發展面向中，出現明顯落後於同齡兒童之情形。其中，粗大動作能力常為較早可被觀察之發展指標，而行走步態更是 12 至 36 個月齡間重要的發展里程碑之一。相關研究指出，若能及早發現異常並及時介入，將有助於改善發展遲緩兒童之長期預後 [1]，因此如何建立及時、有效且可普及之輔助評估方式，已成為臨床與公共衛生領域的重要課題。

目前臨床上常用之發展評估工具，如 Peabody Developmental Motor Scales 第二版 (PDMS-2) [2] 及 Alberta Infant Motor Scale (AIMS) [3]，雖具有良好之信效度，然而多需由受過訓練之專業人員施測，且評估過程較耗時，不易支援高頻率、自然情境及大規模之早期觀察需求。此外，部分評估仍仰賴觀察者對動作品質之判讀，在長期追蹤便利性與跨觀察者一致性上仍存在限制。

近年來，深度學習技術在人體姿態估測 [4]、動作辨識 [5] 及步態分析 [6] 等領域取得突破性進展，為自動化步態發展評估提供了技術基礎。特別是圖卷積網路 (Graph Convolutional Network, GCN) 能以人體骨架的圖結構進行建模，相較於直接使用影像像素或展平序列，更有利於捕捉人體動作之空間拓撲與時間變化特徵。然

而，現有研究多集中於一般動作辨識、成人步態分析或異常動作偵測，針對 12 至 36 個月齡嬰幼兒自然行走步態成熟度進行建模之研究仍相對有限；更重要的是，目前亦較少有研究進一步探討：若以正常發展步態建立月齡估測模型，遲緩個案是否會在預測結果上呈現具方向性之偏差，並進一步作為發展風險之輔助觀察線索。

基於上述背景與研究缺口，本研究旨在建立一套基於正、背面步態影片之嬰幼兒步態發展輔助評估流程，探討以骨架序列進行月齡估測之可行性，並進一步觀察預測偏差是否可作為發展風險之輔助線索。具體而言，本文首先建構由步態影片出發之自動化骨架分析流程，整合姿態估測、追蹤、步態片段擷取與正規化處理，以建立適用於嬰幼兒步態分析之模型輸入；其次，採用部位注意力殘差圖卷積網路結合標籤分布學習進行月齡估測，以表達月齡標註之連續性與鄰近關係；最後，以正常發展個案建立月齡預測模型，並透過遲緩個案之預測偏差與特徵分布進行探索性分析，以觀察步態成熟度與發展風險之潛在關聯。

貳、文獻回顧

一、嬰幼兒步態分析

嬰幼兒步態分析可分為接觸式與非接觸式兩大類。接觸式方法利用穿戴式慣性測量單元 (IMU) 或壓力感測鞋墊擷取運動學數據 [7]，雖能取得精確之三維運動參數，但穿戴設備易影響幼兒自然動作表現，亦增加實際收案與長期追蹤之執行負擔。相較之下，非接觸式方法則基於電腦視覺技術，從影片中提取人體關節位置進行分析 [8]，較適合應用於臨床觀察與居家場域，也較符合低干擾、自然情境之早期觀察需求。

二、人體姿態估測與追蹤

輕量化姿態估測模型的發展使得即時骨架提取成為可能。RTMO (Real-Time Multi-person One-stage) [4] 為一端到端之多人姿態估測模型，可直接輸出 COCO 格式之 17 個關節點，兼具推論效率與偵測性能。為在影片中維持個體追蹤之一致性，常需搭配多目標追蹤方法使用。本研究採用 BoT-SORT [9] 建立穩定之骨架軌跡，以提升後續步態片段擷取與骨架序列分析之可靠性。

三、圖卷積網路

在骨架式動作分析方面，圖卷積網路已廣泛應用於人體動作辨識任務。ST-GCN 首先將骨架序列建模為時空圖，證明圖卷積適合處理人體關節之空間拓撲關係與時間動態 [5]；其後 ResGCN 進一步引入殘差結構與注意力機制，以提升特徵表徵能力 [10]。由於步態成熟度與身體不同部位之協調變化具有高度關聯，本研究選用具人體部位注意力機制之部位注意力殘差圖卷積網路，作為骨架特徵擷取骨幹網路，以強化對步態相關關節特徵之建模能力。

四、標籤分布學習

月齡估測本質上屬具順序性之連續預測問題，若僅以單一標量回歸處理，較難反映相鄰月齡之過渡關係與標註不確定性。標籤分布學習 [11] 將單一標籤擴展為一組機率分布，已被應用於年齡估計等具連續性與模糊邊界之任務 [12]。相較於直接回歸，標籤分布學習更有助於表達月齡間之鄰近關係，因此本研究將其引入嬰幼兒步態月齡估測，以期提升模型對發展連續性的表徵能力。

參、研究方法

一、系統流程

本研究提出一套以單段幼兒步態影片為輸入，透過骨架序列進行月齡估測，並進一步作為發展風險輔助觀察之自動化流程。如圖 3.1 所示，系統流程包括骨架提取、步態片段偵測、關節點正規化，以及基於圖卷積網路與標籤分布學習之月齡預測。




圖 3.1 正、背面步態影片分析流程圖

二、骨架提取與步態片段擷取

本研究使用 RTMO-L 姿態估測模型對影片逐幀進行人體關節點推論，並輸出

COCO 格式之 17 個關節點座標 (x, y, s) ，其中 x 與 y 分別表示關節點在影像平面上的位置， s 表示該關節點之信心分數。為維持時間序列中同一個體之連續性，採用 BoT-SORT 進行多目標追蹤，建立穩定之骨架軌跡。本研究所使用之輸入影片包含正面與背面兩種視角，兩者皆經相同之姿態估測、追蹤、步態片段擷取與正規化流程處理後，統一輸入模型進行訓練與推論。

考量實際錄影情境中可能同時包含成人與幼兒，本研究進一步利用人體比例特徵與姿態條件對追蹤結果進行篩選，以辨識目標幼兒軌跡；對於品質不佳之骨架資料，則透過低信心點剔除、短時間缺失補值及短軌跡排除等處理，以提升後續步態分析之穩定性。

本研究之步態片段擷取採規則式條件篩選，依站立姿態、左右踝關節之交替變化，以及軀幹比例檢查，自連續骨架軌跡中擷取具有穩定步行型態之區段，並切割為固定長度 128 幀之片段作為模型輸入。此設計可在保留主要步態週期資訊之同時，統一模型輸入長度，利於後續訓練與推論。

三、關節點正規化與部位注意力殘差圖卷積網路模型

為降低個體身形差異、攝影距離與姿態估測抖動對特徵學習之影響，本研究對骨架序列進行三階段正規化處理。首先，以左右肩中點作為座標原點，進行平移標準化；其次，以軀幹長度作為參考尺度，進行等比例縮放；最後，沿時間軸施加平滑濾波，以減少逐幀估測抖動。設第 i 個關節點原始座標為 p_i ，左右肩中點為 c_s ，則中心化後可表示為公式(3.1)

$$p'_i = p_i - c_s \quad (3.1)$$

完成正規化後，每段骨架序列可表示為一組多維張量，其中包含關節點座標通道、時間長度、關節點數與個體數等維度，以作為 PA-ResGCN 之輸入。在模型設計上，本研究採用部位注意力殘差圖卷積網路（Part-Attention ResGCN, PA-ResGCN）作為骨架時空特徵擷取模型。該模型透過圖卷積建模人體關節之拓撲關係，並以時間卷積學習步態動作之時序變化；同時加入人體部位注意力機制，使模型能聚焦於與步態成熟度較相關之身體部位特徵。經全域平均池化後，模型輸出高維特徵向量，再接全連接層得到各月齡區間之預測分數。

四、標籤分布學習與訓練策略

傳統月齡預測多以單一標量回歸方式處理，然而此方法較難表達月齡估測之不確定性，以及相鄰月齡之連續關係。因此，本研究將月齡預測建模為標籤分布學習問題，使模型輸出一組月齡分布，而非單一數值

本研究將 12 至 36 個月之月齡範圍劃分為 9 個等距之月齡中心點，如公式(3.2) 所示。

$$b = [12, 15, 18, 21, 24, 27, 30, 33, 36] \quad (3.2)$$

對於真實月齡 y ，本文以 y 為中心建立高斯標籤分布，使模型在學習目標月齡的同時，亦能保留相鄰月齡之鄰近關係與平滑過渡特性。對於第 i 個月齡中心點，其對應之目標機率定義如公式 (3.3) 所示。其中高斯分布之標準差設定為 1.0。

$$q_k = \frac{1}{Z} \exp\left(-\frac{(b_k - y)^2}{2\sigma^2}\right) \quad (3.3)$$

訓練時，模型輸出經 Softmax 轉換為預測分布，並以 Kullback-Leibler 散度作為損失函數，如公式 (3.4) 所示，用以衡量預測分布與目標分布之差異。

$$\mathcal{L}_{KL} = \sum_{k=1}^K q_k \log\left(\frac{q_k}{\hat{p}_k}\right) \quad (3.4)$$

推論階段則以預測分布之期望值作為最終月齡估計，如公式 (3.5) 所示。

$$\hat{y} = \sum_{k=1}^K \hat{p}_k b_k \quad (3.5)$$

模型訓練採用 SGD 作為最佳化方法，初始學習率為 0.01，batch size 為 16，訓練 100 個 epochs。為降低不同受試者影片數量差異對結果之影響，推論階段先對同一受試者之各步態片段分別估測月齡，再將其預測結果取平均，作為該受試者之最終預測月齡。

五、實驗設計

本研究採受試者獨立之五折交叉驗證進行評估，以避免同一受試者之資料同時出現在訓練與驗證階段而造成資訊洩漏。具體而言，130 位正常發展個案依受試者為單位切分為 5 份，各折輪流以其中 4 份作為訓練集、1 份作為驗證集，再彙整整體結果。10 位遲緩個案未納入模型訓練與驗證流程，而僅作為探索性分析資料，用以觀察其預測偏差與特徵分布。在視角設定上，本研究同時納入正面與背面步態影片，並以統一之骨架處理流程建立模型輸入，以學習不同觀察方向下與月齡相關之步態特徵。由於每位受試者實際可取得之影片數量不盡相同，本研究以受試者為資料分析基本單位；自各段影片中擷取出符合條件之步態片段後，統一切割為固定長度 128 幀（30 fps）之骨架序列，以對齊部位注意力殘差圖卷積網路之輸入維度。於模型推論階段，若同一受試者包含多個步態片段，則先分別對各片段估測月齡，再將其預測結果取平均，作為該受試者之最終預測月齡。

肆、實驗結果與討論

一、資料集

本研究與馬偕紀念醫院早期療育團隊合作，收集 12 至 36 個月齡間的幼兒自發性運動影片數據，共收集 140 個案並建立嬰幼兒行走步態資料集。其中 130 個案為評估發展正常，10 個案評估為發展遲緩，具體年齡區間以月齡為單位表示，詳見表 4.1。由表可見，遲緩個案數量相對有限，且 18 個月以下之遲緩樣本特別稀少，因此後續相關結果應以探索性分析角度解讀。

表 4.1 正常組與遲緩組之月齡分布

月齡 發展	月齡								總數
	12~15	15~18	18~21	21~24	24~27	27~30	30~33	33~36	
正常	19	24	21	21	16	17	9	13	130
遲緩	0	2	1	0	3	0	3	1	10
總數	19	26	22	21	19	17	12	14	140

二、評估指標

本研究以月齡預測誤差與排序一致性作為主要評估面向，採用均方誤差（mean squared error, MSE）與斯皮爾曼等級相關係數作為評估指標。均方誤差用以衡量預測月齡與實際月齡之差異，其定義如公式 (4.1) 所示；斯皮爾曼等級相關係數則用以衡量預測結果與實際月齡之單調關係，可反映模型是否掌握月齡遞增之排序趨勢。

$$MSE = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (4.1)$$

在五折交叉驗證下，部位注意力殘差圖卷積網路結合標籤分布學習之模型，其均方誤差為 23.956 ± 7.158 ，斯皮爾曼等級相關係數為 0.735 ± 0.136 。整體結果顯示，本研究方法可自正常發展幼兒之步態骨架序列中學習與月齡相關之時空特徵，並具備一定之月齡排序能力。

三、月齡預測結果

圖 4.1 為月齡預測散佈圖。由圖可見，正常發展個案之預測結果大致隨實際月齡增加而上升，顯示模型已能自步態骨架序列中學習與月齡相關之整體變化趨勢，並具備一定程度之排序與回歸能力。




圖 4.1 月齡預測散佈圖

相較之下，遲緩個案在散佈圖中呈現不同分布型態，尤其於較高月齡區間，部分資料點明顯落於理想對角線下方，亦即其預測月齡低於實際月齡。此結果顯示，雖然模型僅以正常發展個案之月齡作為監督訊號進行學習，但所學得之步態表徵仍可能反映部分發展成熟度不足之特徵，並使遲緩個案呈現相對年幼之步態成熟度趨勢。

為進一步分析預測偏差，圖 4.2 將個案依是否小於 18 個月進行分層，並比較正常發展組與發展遲緩組之預測誤差分布，其中預測誤差定義為預測月齡減去實際月齡。結果顯示，在 18 個月以上之族群中，正常發展組之預測誤差中位數接近 0；相較之下，部分遲緩個案之預測誤差偏向負值，反映其在本模型所學得之步態成熟度表徵上，呈現相對低估之趨勢。此結果初步顯示，預測偏差可能具有作為發展風險輔助觀察線索之潛力，並反映部分遲緩個案在步態成熟度上可能呈現相對落後之現象。




圖 4.2 正常組與遲緩組在 18 個月分層下之預測誤差分布

考量 18 個月常被視為觀察獨立行走是否延遲之重要臨床參考節點，本研究以此作為分層分析基準。然而，由於 18 個月以下之遲緩樣本數極少，本文不主張模型於早期月齡階段即具備穩定之遲緩區辨能力。另一方面，正常組在 18 個月以下區間出現輕度正向偏差，可能與早期步態尚未穩定、個體差異較大，以及樣本分布有限等因素有關。

除輸出結果外，為探討模型內部表徵是否蘊含發展相關資訊，本研究進一步對注意力殘差圖卷積網路全域池化層輸出之 256 維特徵進行主成分分析 (Principal Component Analysis, PCA)，結果如圖 4.3 所示。正常發展個案在特徵空間中大致沿著一條連續軌跡分布，且點之顏色隨真實月齡增加呈現規律變化，顯示模型所學得之潛在特徵與發展成熟度之間具有一致對應關係。

部分真實月齡較高之遲緩個案則未落在正常發展軌跡的高月齡區域，而偏向較低月齡個案聚集的位置，呈現相對落後之現象。此結果與散佈圖中的負向預測偏差相互呼應，說明模型在特徵空間中亦捕捉到與步態成熟度相關之差異。




圖 4.3 主成分分析特徵分布圖

四、結果討論

綜合上述結果，本研究有三點主要發現。首先，部位注意力殘差圖卷積網路結合標籤分布學習之月齡估測架構，能自幼兒正、背面步態影片擷取之骨架序列中學習與月齡遞進相關之時空特徵，此一結果可由月齡預測散佈圖與主成分分析之特徵分布相互印證。其次，雖然模型未直接以遲緩標註進行訓練，部分遲緩個案於較高月齡區間仍呈現較明顯之負向預測偏差，且其潛在特徵分布相對偏離正常發展軌跡，初步顯示預測偏差可能具有作為發展風險輔助觀察線索之潛力。第三，標籤分布學習以分布方式建模相鄰月齡之關係，有助於表達標籤之連續性；然而，其相較於直接標量回歸之實際優勢，仍有待後續基準比較進一步驗證。

本研究亦存在若干限制。首先，資料集規模仍有限，尤其 18 個月以下遲緩樣本數偏少，限制了早期月齡結果之推論。其次，本文對遲緩個案之分析主要建立於預測偏差與特徵視覺化之觀察，尚未納入敏感度、特異度或 AUC 等分類指標進行臨床判別驗證。最後，本研究目前僅使用正、背面兩種固定視角之步態影片，尚未納入側面視角、同步多視角或三維動作資訊。整體而言，本文結果支持以步態骨架進行月齡估測之可行性，並顯示進一步分析預測偏差作為發展風險輔助觀察方向具有研究價值。

伍、結論與未來展望

本研究提出一套基於正、背面步態影片之嬰幼兒步態發展輔助評估流程。方法上，先利用 RTMO 姿態估測與 BoT-SORT 追蹤自動擷取幼兒行走骨架序列，再經步態片段偵測與正規化處理後，輸入部位注意力殘差圖卷積網路結合標籤分布學習進行

月齡估測。於與馬偕紀念醫院早期療育團隊合作蒐集之 140 位 12 至 36 個月齡嬰幼兒資料上，本研究以正常發展個案進行受試者獨立之五折交叉驗證評估，結果顯示所提方法可自步態骨架序列中學習與月齡發展相關之時空特徵。

進一步觀察發現，部分遲緩個案於較高月齡區間呈現較明顯之負向預測偏差，顯示預測偏差可能作為發展風險之輔助觀察線索。然而，由於遲緩樣本數仍有限，本文僅將此結果視為探索性發現。整體而言，本研究支持以步態骨架估測發展月齡之可行性，並顯示其具延伸至發展遲緩輔助觀察之潛力。

未來研究可朝三個方向持續推進：第一，擴充不同年齡區間與遲緩個案樣本數，並於多場域、多設備條件下驗證模型之泛化能力；第二，納入臨床遲緩標註建立更直接對應臨床需求之分類模型，以提供敏感度、特異度與 AUC 等評估指標；第三，進一步整合多視角步態資訊或其他動作特徵，以更完整刻畫嬰幼兒步態成熟度，提升系統之穩定性與實務應用價值。

參考文獻

- [1] Guralnick, Michael J. PhD. Why Early Intervention Works: A Systems Perspective. (2011). *Infants & Young Children* 24(1):p 6-28, January/March 2011.
- [2] Folio, M. R., & Fewell, R. R. (2000). *Peabody Developmental Motor Scales* (2nd ed.). PRO-ED.
- [3] Piper, M. C., & Darrah, J. (1994). *Motor assessment of the developing infant*. W.B. Saunders Company.
- [4] Lu, P., Jiang, T., Li, Y., Li, X., Chen, K., & Yang, W. (2024). RTMO: Towards high-performance one-stage real-time multi-person pose estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 1491-1500). IEEE.
- [5] Yan, S., Xiong, Y., & Lin, D. (2018). Spatial temporal graph convolutional networks for skeleton-based action recognition. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 7444–7452.
- [6] Liao, R., Yu, S., An, W., & Huang, Y. (2020). A model-based gait recognition method with body pose and human prior knowledge. *Pattern Recognition*, 98, Article 107069.
- [7] Taborri J, Palermo E, Rossi S, Cappa P. Gait Partitioning Methods: A Systematic Review. *Sensors (Basel)*. 2016 Jan 6;16(1):66.
- [8] Chambers, C., Seethapathi, N., Saluja, R., Loeb, H., Pierce, S. R., Bogen, D. K., Prosser, L., Johnson, M. J., & Kording, K. P. (2020). Computer vision to automatically assess infant neuromotor risk. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 28(11), 2431–2442.
- [9] Aharon, N., Orfaig, R., & Bobrovsky, B.-Z. (2022). BoT-SORT: Robust associations multi-pedestrian tracking. *arXiv*.
- [10] Song, Y.-F., Zhang, Z., Shan, C., & Wang, L. (2020). Stronger, faster and more explainable: A graph convolutional baseline for skeleton-based action recognition. In *Proceedings of the 28th ACM International Conference on Multimedia* (pp. 1625–1633). Association for Computing Machinery.
- [11] Geng, X. (2016). Label distribution learning. *IEEE Transactions on Knowledge and Data Engineering*, 28(7), 1734–1748.
- [12] Geng, X., Yin, C., & Zhou, Z.-H. (2013). Facial age estimation by learning from label distributions. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(10), 2401–2412.